

SKRIPSI
IMPLEMENTASI SISTEM PENCARIAN SEMANTIK MENGGUNAKAN
MINILM-RAG PADA ARSIP DOKUMEN DIGITAL PERGURUAN
TINGGI



Disusun oleh:
Andrian Maulana
NIM: 442023611059

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS DARUSSALAM GONTOR
2026 / 1448

ABSTRAK

Institusi perguruan tinggi sangat bergantung pada arsip digital untuk mengelola dokumen administratif dan akademik. Sistem temu kembali informasi berbasis kata kunci konvensional kerap gagal menangkap relasi semantik antara kueri pengguna dan dokumen arsip, sehingga menghasilkan relevansi pencarian yang kurang optimal. Penelitian ini mengusulkan sistem pencarian semantik dan *Retrieval-Augmented Generation* (RAG) untuk pengelolaan arsip akademik di Universitas Darussalam Gontor. Sistem ini memanfaatkan model *sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2* yang telah diadaptasi ke dalam domain spesifik, dilatih menggunakan augmentasi data sintesis *threefold* serta fungsi *Multiple Negatives Ranking Loss*. Representasi vektor dokumen (*embeddings*) diindeks pada ChromaDB menggunakan metrik *cosine similarity*, sementara *Cross-Encoder* multibahasa melakukan pengurutan ulang hibrida (*hybrid reranking*) sebelum konteks yang relevan diteruskan ke *Large Language Model* lokal. Hasil eksperimen terhadap 784 dokumen arsip menunjukkan bahwa model SBERT MiniLM hasil *fine-tuning* dengan augmentasi data sintesis mampu mencapai nilai *Accuracy@1* sebesar 0,923, *Precision@1* sebesar 0,923, *Recall@5* sebesar 0,9936, *NDCG@10* sebesar 0,9632, dan *MRR@10* sebesar 0,9511, yang mengungguli kualitas pemeringkatan model *pre-trained* MiniLM, model MiniLM *fine-tuned* tanpa augmentasi data sintesis, maupun MPNet multibahasa. Alur kerja (*pipeline*) RAG kemudian dievaluasi menggunakan Llama 3.2, Gemma 2, dan Qwen 2.5. Model Gemma 2 mencatatkan performa keseluruhan terbaik, dengan skor *faithfulness* sebesar 0,97, *answer relevancy* sebesar 0,89, *context precision* sebesar 0,91, serta rata-rata waktu komputasi *end-to-end (latency)* sebesar 6,07 detik. Temuan ini menunjukkan bahwa penggunaan model MiniLM berparameter ringan yang diadaptasi secara domain, dikombinasikan dengan pengurutan ulang hibrida dan *pipeline* RAG lokal, mampu menyediakan akses informasi arsip akademik yang akurat dan efisien secara komputasi.

Kata kunci: Pencarian Semantik, NLP, ChromaDB, RAG, Sistem Pengambilan Informasi.

ABSTRACT

Academic institutions rely on digital archives to manage administrative and academic documents. Conventional keyword-based retrieval systems often fail to capture semantic relationships between user queries and academic archive documents, resulting in suboptimal retrieval relevance. This study proposes a semantic search and Retrieval-Augmented Generation system for academic archives at Universitas Darussalam Gontor. The system employs a domain-adapted paraphrase-multilingual-MiniLM-L12-v2 model trained using threefold synthetic data augmentation and Multiple Negatives Ranking Loss. Document embeddings are indexed in ChromaDB using cosine similarity, while a multilingual Cross-Encoder performs hybrid reranking before the retrieved contexts are passed to a local Large Language Model. Experiments on 784 archive documents show that the fine-tuned MiniLM model achieves an Accuracy@1 of 0,923, precision@1 of 0,923, Recall@5 of 0,9936, NDCG@10 of 0,9632, and MRR@10 of 0,9511, outperforming the MiniLM baseline and multilingual MPNet in ranking quality. The RAG pipeline was evaluated using Llama 3.2, Gemma 2, and Qwen 2.5. Gemma 2 achieved the best overall performance, with a faithfulness score of 0,97, answer relevancy of 0,89, context precision of 0,91, and an average end-to-end latency of 6.07 seconds. These findings demonstrate that a lightweight, domain-adapted MiniLM combined with hybrid reranking and a local RAG pipeline can provide accurate and computationally efficient access to academic archive information.

Keywords: *semantic search; NLP; ChromaDB; RAG; retrieval information.*

LEMBAR PERSETUJUAN

MINILM-RAG: SISTEM PENCARIAN SEMANTIK UNTUK ARSIP
DIGITAL PERGURUAN TINGGI

SKRIPSI

Diajukan untuk memenuhi sebagian persyaratan memperoleh gelar Sarjana Komputer (S.Kom.)

Disusun oleh:

Andrian Maulana

NIM: 442023611059

Telah diperiksa dan disetujui oleh:


Dosen Pembimbing I



Dini Muriyatmoko, S.ST., M.T.

NIY: 150489

Dosen Pembimbing II



Assoc. Prof. Dr. Ir. Oddy Virgantara Putra,
S.Kom., M.T., IPP

NIY: 160589

PENGESAHAN

**MINILM-RAG: SISTEM PENCARIAN SEMANTIK UNTUK ARSIP
DIGITAL PERGURUAN TINGGI**

SKRIPSI

Diajukan untuk memenuhi sebagian persyaratan memperoleh gelar Sarjana Komputer (S.Kom.)

Disusun oleh:

Andrian Maulana

NIM: 442023611059

Skripsi ini telah diuji dan dinyatakan lulus pada

15 Agustus 2026

Telah diperiksa dan disetujui oleh:

Dosen Pembimbing I

Dosen Pembimbing II

Dihin Muriyatmoko, S.ST., M.T.

NIY: 150489

**Assoc. Prof. Dr. Ir. Oddy Virgantara Putra,
S.Kom., M.T., IPP**

NIY: 160589

Dosen Penguji I

Aziz Musthafa S.Kom, M.T.

NIY: 150489

Mengetahui

Ketua Prodi Teknik Informatika

Dihin Muriyatmoko, S.ST., M.T.

NIY: 150489

PERNYATAAN ORISINALITAS

Saya menyatakan dengan sesungguhnya bahwa sepanjang pengetahuan saya, dalam naskah skripsi ini tidak terdapat karya ilmiah yang pernah diajukan oleh orang lain untuk memperoleh gelar akademik di suatu perguruan tinggi, serta tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis dikutip dalam naskah ini dan disebutkan dalam daftar pustaka.

Apabila terbukti bahwa naskah skripsi ini mengandung unsur plagiat, saya bersedia agar skripsi ini digugurkan dan gelar akademik yang telah saya peroleh (sarjana) dibatalkan, serta diproses sesuai dengan peraturan perundang-undangan yang berlaku (UU No. 20 Tahun 2003, Pasal 25 ayat 2 dan Pasal 70).

Saya juga menyatakan bahwa dalam proses penulisan skripsi ini, saya menggunakan bantuan (AI) berupa Claude dan Gemini secara terbatas, hanya untuk memperbaiki struktur kalimat. Segala gagasan, analisis, dan tanggung jawab akademik sepenuhnya tetap menjadi milik saya sebagai penulis.

Ponorogo, 03 Agustus 2026

Andrian Maulana

NIM: 442023611059

KATA PENGANTAR

Puji syukur ke hadirat Allah SWT atas segala rahmat, hidayah, serta karunia-Nya sehingga penulis dapat menyelesaikan penulisan skripsi berjudul “MINILM-RAG: SISTEM PENCARIAN SEMANTIK UNTUK ARSIP DIGITAL PERGURUAN TINGGI”. Penyusunan tugas akhir ini merupakan salah satu syarat akademik untuk menuntaskan studi jenjang strata satu (S1) dan memperoleh gelar Sarjana Komputer pada Program Studi Teknik Informatika, Fakultas Sains dan Teknologi, Universitas Darussalam Gontor.

Penulis menyadari bahwa kelancaran proses penelitian dan penyelesaian skripsi ini tidak terlepas dari doa, bimbingan, arahan, serta dukungan dari berbagai pihak. Oleh karena itu, dengan penuh rasa hormat penulis ingin menyampaikan ungkapan terima kasih yang sebesar-besarnya kepada:

1. Al-Ustadz Prof. Dr. Hamid Fahmy Zarkasyi, M.A.Ed., M.Phil., selaku Rektor Universitas Darussalam Gontor beserta seluruh jajaran pimpinan universitas dan segenap dosen yang telah mendidik, membimbing, serta memfasilitasi lingkungan akademik yang kondusif.
2. Al-Ustadz Dr. Haris Setyaningrum, M.Sc., selaku Dekan Fakultas Sains dan Teknologi Universitas Darussalam Gontor, beserta jajarannya atas segala kemudahan operasional dan dukungan selama masa studi.
3. Al-Ustadz Dihin Muriyatmoko, S.ST., M.T., selaku Ketua Program Studi Teknik Informatika Universitas Darussalam Gontor, yang senantiasa memberikan arahan dan motivasi kepada para mahasiswa.
4. Al-Ustadz Dihin Muriyatmoko, S.ST., M.T., selaku Dosen Pembimbing I yang dengan penuh kesabaran telah meluangkan waktu, tenaga, dan keilmuannya untuk memberikan bimbingan, masukan berharga, serta arahan dari awal perumusan masalah hingga penyelesaian penelitian ini.
5. Al-Ustadz Assoc. Prof. Dr. Ir. Oddy Virgantara Putra, S.Kom., M.T., IPP., selaku Dosen Pembimbing II yang senantiasa memberikan arahan, motivasi, serta pandangan keilmuan yang sangat berarti dalam penyempurnaan penyusunan tugas akhir ini.
6. Segenap staf administrasi dan pihak-pihak terkait di lingkungan Universitas

Darussalam Gontor yang telah banyak membantu serta memberikan izin akses dalam proses pengumpulan data dokumen arsip kampus untuk keperluan eksperimen sistem pada penelitian ini.

7. Seluruh pihak yang telah memberikan kontribusi nyata, baik secara materiil maupun immateriil dalam penyusunan tugas akhir ini, yang tidak dapat penulis sebutkan satu per satu.

Penulis menyadari sepenuhnya bahwa karya tulis ilmiah ini masih memiliki kekurangan dan jauh dari kata sempurna akibat keterbatasan pengalaman serta ilmu yang penulis miliki. Oleh karena itu, kritik dan saran yang konstruktif sangat penulis harapkan untuk penyempurnaan karya di masa yang akan datang. Akhir kata, penulis berharap semoga skripsi ini mampu memberikan sumbangsih keilmuan, manfaat praktis bagi institusi, serta menjadi referensi yang berguna bagi penelitian selanjutnya, khususnya dalam bidang sistem temu kembali informasi (*information retrieval*) dan pemrosesan bahasa alami (*natural language processing*).

Ponorogo, 26 Juli 2026

Andrian Maulana
NIM: 442023611059

DAFTAR ISI

ABSTRAK.....	1
ABSTRACT.....	2
PENGESAHAN	4
PERNYATAAN ORISINALITAS	5
KATA PENGANTAR	6
DAFTAR ISI.....	8
DAFTAR TABEL.....	10
DAFTAR GAMBAR.....	11
DAFTAR PERSAMAAN.....	12
BAB I.....	1
1.1 Latar Belakang Penelitian	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian.....	3
1.4 Manfaat Penelitian.....	3
1.5 Ruang Lingkup Studi	4
1.6 Pembahasan Studi	5
BAB II.....	6
2.1 Landasan Teori.....	6
2.1.1 Dokumen Arsip Digital	6
2.1.2 <i>Semantic Search</i>	6
2.1.3 <i>Sentence Embedding</i>	6
2.1.4 <i>Mini Language Model (MiniLM)</i>	6
2.1.5 <i>Cosine Similarity</i>	7
2.1.6 <i>Vector Database</i>	7
2.1.7 <i>Retrieval Augmented Generation (RAG)</i>	7
2.1.8 <i>Retrieval Augmented Generation Assessment (RAGAS)</i>	7
2.2 Penelitian Terdahulu	8
2.2.1 <i>Semantic & Vector-Based Retrieval</i>	8
2.2.2 <i>Mini Language Model & Semantic Similarity</i>	8
2.2.3 <i>Perbandingan Keyword-Based vs Semantic Search</i>	9
2.2.4 <i>Transformers-Based Information Retrieval</i>	10
2.2.5 <i>Multimodal Document Retrieval</i>	10
BAB III	16
3.1 Waktu Penelitian	16

3.2 Alat dan Bahan Penelitian	16
3.3 Model Penelitian	17
3.4 Tahapan Penelitian	17
3.5 Arsitektur Sistem.....	19
3.5.1 Pengumpulan, Pemrosesan, dan Augmentasi Data	19
3.5.2 Pelatihan Embedding Model (<i>Fine-Tuned Mini Language Model</i>)	20
3.5.3 Penyimpanan dan pengindeksian Vektor (<i>Vector Indexing</i>)	21
3.5.4 Pemrosesan Kueri (<i>Query Processing</i>).....	22
3.5.5 Perhitungan Kemiripan (<i>Similarity Calculation</i>)	22
3.5.6 Pemeringkatan dan Penyajian Hasil (<i>Ranking & Retrieval</i>)	23
3.5.7 Evaluasi Model Embedding (<i>Embedding Model Evaluation</i>).....	23
3.5.8 Pemeringkatan Ulang Kontekstual (<i>Cross-Encoder Reranking</i>).....	26
3.5.9 Pengayaan Konteks dan Rekayasa Prompt (<i>Context Enrichment & Prompt Engineering</i>)	27
3.5.10 Pembentukan Respons RAG (<i>LLM Generation / Agentic RAG</i>).....	27
3.5.11 Evaluasi Kualitas RAG (<i>RAGAS Framework</i>)	27
BAB IV	29
4.1 Hasil Penelitian	29
4.1.1 Prapemrosesan Data	29
4.1.2 Pelatihan Model Semantik (<i>Fine-Tuned</i>) dan Analisis Komparasi	30
4.2 Hasil Evaluasi Arsitektur Sistem.....	31
4.2.1 Hasil Evaluasi <i>Information Retrieval</i> (IR).....	31
4.2.2 Hasil Evaluasi Kualitas Jawaban LLM (<i>RAG-Assessment</i>)	35
4.2.3 Analisis Efisiensi Waktu Komputasi (<i>Latency Evaluation</i>)	36
4.3 Pembahasan.....	37
BAB V	39
5.1 Kesimpulan.....	39
5.2 Saran.....	40
DAFTAR PUSTAKA	42
LAMPIRAN.....	45

DAFTAR TABEL

Tabel 1. Perbandingan Penelitian Terdahulu dengan Penelitian Sekarang.....	12
Tabel 2. Waktu Penelitian.....	16
Tabel 3. Hasil Distribusi dan Premrosesan Dataset	29
Tabel 4. Parameter Pelatihan Model MiniLM	30
Tabel 5. Hasil Evaluasi Information Retrieval	31
Tabel 6. Hasil Evaluasi RAGAS Berdasarkan Model LLM.....	35
Tabel 7. Distribusi Latensi Sistem (Rata-rata Per Kueri)	36

DAFTAR GAMBAR

Gambar 1. Tahapan Penelitian.....	18
Gambar 2. Arsitektur Sistem.....	19
Gambar 3. Metrik Evaluasi Information Retrieval	32
Gambar 4. Nilai Efisiensi Model	34
Gambar 5. Evaluasi RAGAS 20 kueri pada model Llama.....	45
Gambar 6. Evaluasi RAGAS 20 kueri pada model Qwen	45
Gambar 7. Evaluasi RAGAS 20 kueri pada model Gemma	45
Gambar 8. Inference Semantic Search.....	46
Gambar 9. Inference Semantic Search.....	47
Gambar 10. Hasil Pemrosesan Dataset	47
Gambar 11. Perbandingan Kualitas dan Latency Tiap Model LLM.....	48

DAFTAR PERSAMAAN

Persamaan 1. Scale Dot-Product Attention.....	20
Persamaan 2. Average Pooling	20
Persamaan 3. Cosine Similarity	22
Persamaan 4. Accuracy Top-k	24
Persamaan 5. Precision Top-k.....	24
Persamaan 6. Recall Top-k	24
Persamaan 7. Mean Reciprocal Rank	25
Persamaan 8. Mean Average Precision.....	25
Persamaan 9. Average Precision.....	25
Persamaan 10. Normalized Discounted Cumulative Gain.....	26
Persamaan 11. Hybrid Scoring Function	26
Persamaan 12. Temperature-Scaled Softmax Function	27

BAB I

PENDAHULUAN

1.1 Latar Belakang Penelitian

Perkembangan teknologi informasi telah berdampak pada perguruan tinggi untuk melakukan transformasi digital dalam pengelolaan arsip dan dokumentasi institusi. Dokumen administrasi seperti Surat Keputusan (SK), Standar Operasional Prosedur (SOP), surat-menyurat, laporan kegiatan, panduan akademik, serta dokumen pendukung akreditasi saat ini sebagian besar telah dialihkan ke dalam bentuk digital. Berdasarkan pada standar internasional ISO 15489-1:2016, pengelolaan arsip digital yang baik bertujuan untuk menjamin autentisitas, reliabilitas, integritas, dan ketergunaan arsip sebagai bukti kegiatan organisasi yang sah [1]. Namun, seiring dengan pertumbuhan eksponensial volume dokumen digital di lingkungan kampus, muncul tantangan baru dalam menciptakan mekanisme pencarian informasi (*information retrieval*) yang efektif dan efisien.

Pentingnya ketepatan dalam penyampaian dan pencarian informasi yang telah diisyaratkan dalam Al-qur'an, sebagaimana firman Allah SWT pada QS. Al-Ahzab ayat 70:

يَا أَيُّهَا الَّذِينَ آمَنُوا اتَّقُوا اللَّهَ وَقُولُوا قَوْلًا سَدِيدًا

"Wahai orang-orang yang beriman, bertakwalah kalian kepada allah dan katakanlah perkataan yang benar."

Pada praktiknya, sistem pencarian arsip di banyak perguruan tinggi masih didominasi oleh metode pencarian berbasis kata kunci (*keyword-based search*) atau pencocokan leksikal (*lexical matching*). Metode ini bekerja dengan mencocokkan string kata yang dimasukkan pengguna dengan kata-kata yang ada dalam dokumen secara harfiah. Pendekatan ini memiliki keterbatasan mendasar karena gagal menangkap hubungan semantik atau makna di balik kata-kata tersebut. Masalah seperti polisemi (satu kata banyak makna) dan sinonimi (kata berbeda makna sama) seringkali menyebabkan fenomena *vocabulary mismatch*, di mana dokumen yang relevan gagal ditemukan hanya karena tidak mengandung kata kunci yang persis sama dengan kueri pengguna [2].

Untuk mengatasi keterbatasan tersebut, pendekatan Semantic Search yang menggunakan *Natural Language Processing* (NLP) menawarkan solusi yang lebih cerdas. Berbeda dari pencarian konvensional, semantic search menggunakan representasi vektor

(embedding) untuk memahami konteks dan maksud pengguna. Teknik ini memetakan teks ke dalam ruang vektor (*vector space*), sehingga dokumen yang memiliki makna yang sama akan berjarak vektor yang dekat [3]. Perkembangan penting dalam bidang ini terlihat dari munculnya arsitektur *Dense Passage Retrieval* (DPR) [4] yang terbukti lebih unggul daripada metode tradisional seperti BM25 dalam tugas menjawab pertanyaan di domain terbuka.

Salah satu metode canggih dalam pembuatan embedding adalah Sentence-BERT (SBERT), yang mengadaptasi arsitektur BERT dengan jaringan siamese untuk menghasilkan representasi kalimat yang bisa dibandingkan secara efisien melalui perhitungan *Cosine Similarity* [5]. Meski model Transformer seperti BERT menawarkan akurasi tinggi, ukurannya yang besar menyebabkan kebutuhan sumber daya komputasi yang tinggi dan waktu inferensi yang lambat, yang menjadi kendala pada infrastruktur kampus dengan sumber daya terbatas [6].

Sebagai solusi atas masalah efisiensi tersebut, dikembangkan model MiniLM (*Miniature Language Model*). MiniLM dibuat menggunakan teknik *Deep Self-Attention Distillation*, yang memungkinkan model kecil meniru kemampuan model yang lebih besar seperti BERT, tetapi dengan kecepatan proses yang lebih tinggi dan penggunaan memori yang lebih efisien [7]. Efektivitas *Sentence Transformer* MiniLM terbukti dalam studi terbaru oleh Putra et al. (2025) yang menggunakan model ini dalam sistem rekomendasi artikel ilmiah. MiniLM mampu memberikan rekomendasi yang relevan dengan efisiensi komputasi yang tinggi [8].

Namun, salah satu kendala utama dalam melatih model pencarian semantik untuk domain spesifik seperti arsip kampus adalah ketiadaan data riwayat pencarian (*search logs*) dari pengguna. Untuk mengatasi hal ini, penelitian ini mengusulkan penggunaan teknik *Rule-Based Data Augmentation* agar model yang dihasilkan lebih optimal. Selain itu, demi mendukung efisiensi dan skalabilitas data, sistem tidak menyimpan vektor secara statis, melainkan mengintegrasikannya melalui *Vector Database*, yaitu ChromaDB. Berdasarkan penjelasan tersebut, penelitian ini berfokus pada penerapan semantic document retrieval berbasis *Sentence Transformer* MiniLM yang dieksperimenkan melalui teknik augmentasi data untuk meningkatkan kualitas pencarian dokumen arsip kampus.

Berdasarkan uraian tersebut, penelitian ini membahas penggunaan *semantic document retrieval* berbasis *Sentence Transformer* MiniLM-RAG untuk meningkatkan

akurasi pencarian dokumen arsip di Universitas Darussalam Gontor. Sistem ini dibangun untuk membantu pengguna menemukan dokumen yang relevan secara semantik, mendukung pengelolaan arsip digital yang lebih efisien, serta meningkatkan layanan informasi di lingkungan perguruan tinggi.

1.2 Rumusan Masalah

Berdasarkan masalah yang dijelaskan pada latar belakang, rumusan masalah yang dapat dirumuskan adalah bahwa sistem pencarian dokumen arsip kampus saat ini masih didominasi oleh metode berbasis kata kunci (*keyword-based*) yang memiliki keterbatasan dalam memahami konteks makna, sehingga sering kali tidak menghasilkan hasil yang relevan secara semantik.

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah disebutkan, tujuan penelitian ini meliputi pembangunan sistem pencarian dokumen arsip kampus berbasis semantic search. Sistem ini menggunakan *Sentence Transformer* MiniLM-RAG dan teknik augmentasi data sintetis untuk mengatasi keterbatasan metode berbasis kata kunci dalam memahami konteks makna serta meningkatkan relevansi hasil pencarian dan menghasilkan respons terhadap kueri pengguna.

1.4 Manfaat Penelitian

Peneliti berharap hasil penelitian ini akan memberikan beberapa manfaat, di antaranya sebagai berikut:

1. Bagi peneliti

- a. Memberikan wawasan praktis mengenai penerapan NLP dan pencarian semantik dalam sistem nyata, serta menjadi sumber belajar untuk mengembangkan sistem AI berbasis semantic search dengan *Sentence Transformer* MiniLM-RAG.

2. Bagi pembaca

- a. Memperoleh pemahaman tentang pengembangan teknologi pencarian informasi yang lebih cerdas dan user-friendly, terutama pada sistem arsip digital berbahasa Indonesia.

3. Bagi instansi perguruan tinggi

- a. Sistem ini membantu staf administrasi dan sivitas akademika menemukan dokumen arsip dengan lebih cepat dan efisien, serta mempercepat proses

akses informasi bagi sivitas akademika.

4. Bagi peneliti lain

- a. Hasil penelitian ini dapat menjadi dasar empiris untuk studi lanjutan dalam bidang pencarian semantik, terutama yang memanfaatkan korpus berbahasa Indonesia dalam konteks institusi pendidikan. Pendekatan augmentasi data yang digunakan dapat diadaptasi oleh peneliti yang menghadapi kendala serupa, seperti keterbatasan data historis pencarian pengguna.

1.5 Ruang Lingkup Studi

Penelitian ini berfokus pada sistem temu kembali informasi (information retrieval), khususnya pada implementasi pencarian semantik untuk pengelolaan dokumen administratif di perguruan tinggi. Tujuan utamanya adalah merancang sistem pencarian arsip berbasis teks yang secara khusus menangani Surat Keputusan (SK), Standar Operasional Prosedur (SOP), surat-menyurat, serta laporan kegiatan. Pendekatan yang diterapkan melibatkan model *Sentence Transformer* dengan arsitektur dasar *paraphrase-multilingual-MiniLM-L12-v2* dan RAG yang memanfaatkan LLM, di mana metode *cosine similarity* digunakan sebagai dasar perhitungan untuk mengukur kedekatan semantik antarkata.

Data yang digunakan dalam pengujian sistem ini meliputi 784 dokumen arsip resmi dari Universitas Darussalam Gontor. Untuk memperoleh analisis performa yang lengkap, penelitian ini menggunakan skenario evaluasi silang dengan dua model pembandingan. Model pertama adalah *Sentence Transformer* MiniLM pre-trained murni tanpa proses augmentasi data, berfungsi sebagai model dasar, sedangkan model kedua adalah *Sentence-BERT* (SBERT) berbasis MPNet dengan kapasitas parameter yang lebih besar.

Lebih lanjut, tahap evaluasi dalam penelitian ini sepenuhnya difokuskan pada kualitas teknis algoritma pencarian. Pengukuran efektivitas sistem dianalisis melalui metrik standar evaluasi penelusuran informasi, termasuk *Accuracy@k*, *Precision@k*, *Recall@k*, *Mean Reciprocal Rank (MRR@10)*, *Normalized Discounted Cumulative Gain (NDCG@10)*, serta *Mean Average Precision (MAP@100)*. Selain itu, evaluasi *Retrieval-Augmented Generative* dilakukan dengan RAG-Assessment (RAGAS), yang mengukur *faithfulness*, *answer relevancy*, dan *context precision*. Agar fokus tetap pada kecerdasan buatan dan pemrosesan bahasa alami, penelitian ini membatasi cakupannya dan tidak membahas aspek sistem keamanan data maupun manajemen hak akses pengguna (*user*

access control) pada infrastruktur perangkat lunaknya.

1.6 Pembahasan Studi

Sistematika penulisan dalam penelitian ini terdiri dari lima bagian sebagai berikut:

Bab 1 Pendahuluan

- 1.1. Latar Belakang Penelitian
- 1.2. Rumusan Masalah
- 1.3. Tujuan Penelitian
- 1.4. Manfaat Penelitian
- 1.5. Ruang Lingkup Studi
- 1.6 Pembahasan Studi

Bab 2 Tinjauan Pustaka

- 2.1. Landasan Teori
- 2.2. Penelitian Terdahulu

Bab 3 Metodologi Penelitian

- 3.1. Rencana Kegiatan
- 3.2. Alat dan Bahan
- 3.3. Tahapan Penelitian
- 3.4. Arsitektur Sistem

Bab 4 Hasil dan Pembahasan

- 4.1. Hasil
- 4.2. Pembahasan

Bab 5 Penutup

- 5.1. Kesimpulan
- 5.2. Saran

BAB II

TINJAUAN PUSTAKA

2.1 Landasan Teori

2.1.1 Dokumen Arsip Digital

Dokumen arsip digital adalah catatan kegiatan atau peristiwa yang dibuat oleh individu atau lembaga saat menjalankan fungsi dan tugasnya, lalu disimpan dalam format digital sebagai pertanggungjawaban, bukti kegiatan, dan sumber informasi. Perkembangan teknologi informasi telah mendorong peralihan dari arsip konvensional ke arsip digital untuk meningkatkan efisiensi penyimpanan, kemudahan akses, dan kecepatan dalam menemukan kembali informasi. Namun, peningkatan volume dokumen digital juga menimbulkan tantangan dalam pencarian informasi yang relevan secara cepat dan akurat, terutama ketika pencarian bergantung pada kata kunci eksplisit [1].

2.1.2 *Semantic Search*

Semantic search adalah metode pencarian yang berfokus pada pemahaman makna dan konteks dari query pengguna serta isi dokumen, bukan hanya pada pencocokan kata kunci. Pendekatan ini menggunakan representasi semantik teks, sehingga sistem dapat menemukan dokumen yang relevan meskipun kata-kata yang digunakan tidak sama secara literal dengan kueri. Dalam pengelolaan arsip digital, semantic search dianggap lebih efektif karena dapat memenuhi kebutuhan pengguna yang sering memakai variasi bahasa, sinonim, atau kalimat tidak baku saat mencari [9].

2.1.3 *Sentence Embedding*

Sentence embedding merupakan teknik untuk merepresentasikan teks sebagai vektor numerik berdimensi tetap yang menggambarkan makna semantik suatu kalimat atau dokumen. Dengan metode ini, teks yang memiliki makna serupa akan dipetakan ke vektor yang berdekatan dalam ruang vektor. Pendekatan ini menjadi komponen kunci dalam semantic search karena memungkinkan pengukuran kesamaan makna antara query dan dokumen secara matematis. Biasanya, sentence embedding dihasilkan melalui model deep learning, terutama menggunakan arsitektur transformer [3].

2.1.4 *Mini Language Model (MiniLM)*

MiniLM (*paraphrase-multilingual-MiniLM-L12-v2*) adalah model *sentence*

transformer ringan yang dirancang untuk menghasilkan embedding berkualitas tinggi dengan beban komputasi yang lebih rendah dibandingkan model besar seperti BERT. Menggunakan teknik *knowledge distillation*, MiniLM mampu mentransfer pengetahuan dari model besar ke model yang lebih kecil tanpa mengorbankan performa secara signifikan. Model ini sangat cocok untuk implementasi pencarian semantik dalam sistem arsip digital karena mampu menyeimbangkan akurasi pencarian dan efisiensi sumber daya komputasi [8].

2.1.5 Cosine Similarity

Cosine similarity adalah metode untuk menilai kemiripan antara dua vektor dengan menghitung jarak nilai di antara keduanya. Nilai ini berkisar dari 0 hingga 1, dengan nilai yang mendekati 1 menunjukkan kemiripan semantik yang lebih tinggi. Dalam sistem pencarian berbasis embedding, *cosine similarity* digunakan untuk menilai relevansi antara vektor embedding kueri pengguna dan vektor embedding dokumen arsip. Dokumen dengan nilai similarity tertinggi akan menjadi rekomendasi utama sebagai hasil pencarian [10].

2.1.6 Vector Database

Vector Database adalah sistem manajemen berbasis data yang dirancang khusus untuk menyimpan, mengindeks, dan mencari representasi vektor berdimensi tinggi secara efisien. ChromaDB menggunakan algoritma *Approximate Nearest Neighbor* (ANN) seperti HNSW (*Hierarchical Navigable Small World*) yang menjadikan pencarian semantik berjalan dengan sangat cepat meskipun dengan volume data yang besar dan jauh mengungguli pencarian sekuensial tradisional [11], [12].

2.1.7 Retrieval Augmented Generation (RAG)

Retrieval-Augmented Generation adalah arsitektur sistem yang menggabungkan sistem pencarian informasi (*information retrieval*) dengan model bahasa besar (*Large Language Models*) untuk menghasilkan teks yang lebih akurat, faktual, dan kontekstual. Pendekatan ini secara efektif mengatasi kekurangan utama LLM mentah atau tanpa RAG, seperti halusinasi data dan keterbatasan pengetahuan di domain tertentu, dengan menyisipkan basis pengetahuan eksternal sebagai konteks sebelum proses generasi teks dimulai [13].

2.1.8 Retrieval Augmented Generation Assessment (RAGAS)

RAGAS adalah sistem evaluasi otomatis yang dirancang khusus untuk

menilai dan memvalidasi performa sistem RAG secara menyeluruh tanpa bergantung pada data berlabel dari manusia. Kerangka ini memanfaatkan metrik berbasis LLM (*LLM as a judge*) untuk menilai dua aspek utama: kualitas komponen pencarian (*retrieval*) dan kualitas pembuatan teks (*generation*). Metrik yang digunakan meliputi *Faithfulness*, *Answer Relevancy*, dan *Context Precision*. Pendekatan ini memastikan penilaian performa sistem RAG secara objektif, menghasilkan respons yang relevan, serta meminimalkan halusinasi [14].

2.2 Penelitian Terdahulu

2.2.1 *Semantic & Vector-Based Retrieval*

Safar dkk. (2025) melakukan penelitian tentang sistem rekomendasi yang memanfaatkan *Large Language Model* untuk menghasilkan semantic embeddings berkualitas tinggi. Dalam penelitiannya, mereka mengintegrasikan FAISS (*Facebook AI Similarity Search*) sebagai mesin pencarian kemiripan yang dapat bekerja secara efisien pada skala data yang besar. Arsitektur sistem yang dibangun menggunakan *Sentence Transformers* untuk proses encoding teks, kemudian dipadukan dengan HNSW indexing untuk mempercepat proses retrieval dokumen.

Hasil eksperimen menunjukkan bahwa sistem yang dikembangkan mampu memberikan rekomendasi dengan akurasi lebih tinggi dan waktu respons kurang dari 100 milidetik, bahkan saat diuji pada dataset yang berisi jutaan item. Selain itu, penggunaan FAISS indexing secara signifikan mengurangi beban komputasi hingga 80% dibandingkan metode *brute-force* konvensional, tanpa mengorbankan tingkat recall yang tetap di atas 95%. Penelitian ini menegaskan bahwa pendekatan berbasis embedding semantik dapat diimplementasikan secara efisien dalam sistem berskala besar [3].

2.2.2 *Mini Language Model & Semantic Similarity*

Putra dkk. (2025) mengembangkan sistem rekomendasi artikel ilmiah yang memanfaatkan pendekatan *similarity semantic* berbasis Sentence Transformers. Penelitian ini menggunakan model all-MiniLM-L6-v2 yang diterapkan pada dataset arXiv di bidang Computer Science dengan 15.504 dokumen. Sistem ini berbasis aplikasi web Streamlit untuk memudahkan pengguna mendapatkan rekomendasi artikel berdasarkan kemiripan makna dengan kueri yang dimasukkan.

Hasil evaluasi menunjukkan bahwa teks Introduction tanpa preprocessing

menghasilkan performa yang lebih baik dibandingkan dengan abstrak atau kombinasi bagian teks lainnya. Pengukuran dilakukan menggunakan metrik standar information retrieval: Precision, MAP (*Mean Average Precision*), MRR (*Mean Reciprocal Rank*), dan NDCG (*Normalized Discounted Cumulative Gain*). Teks Introduction tanpa preprocessing mencapai hasil terbaik dengan NDCG sebesar 0,7590, MAP sebesar 0,6960, MRR sebesar 0,7254, dan Precision sebesar 0,5221. Selain evaluasi kuantitatif, penelitian ini juga melibatkan uji pengguna yang menunjukkan bahwa 95,5% responden puas dengan relevansi rekomendasi dan 93,3% merasa waktu pencarian menjadi lebih singkat. Penelitian ini membuktikan bahwa semantic search berbasis embedding dapat digunakan untuk mengembangkan sistem rekomendasi artikel ilmiah baru [8].

2.2.3 Perbandingan *Keyword-Based vs Semantic Search*

Menurut Formal dkk. (2024), mereka mengembangkan dan menilai model SPLADE (*S*parse *L*exical *A*nd *E*xpansion) untuk pencarian informasi yang menggabungkan keunggulan representasi sparse dengan kemampuan pemahaman semantik dari model bahasa yang telah dilatih. Penelitian ini didasari oleh kekurangan mendasar pada metode pencarian berbasis pencocokan kata kunci seperti BM25, yang tidak mampu memahami hubungan antarkata yang kompleks serta memodelkan makna secara akurat. Meskipun sederhana dan efisien, pendekatan berbasis kata kunci terbatas pada metrik statistik kata dan gagal menangkap makna konteks.

Model SPLADE dibangun dengan DistilBERT sebagai dasar utama dan mengintegrasikan kepala MLM (*M*asked *L*anguage *M*odel) untuk mempelajari representasi yang lebih sparse. Proses pelatihan mengoptimalkan ranking loss bersamaan dengan regularisasi FLOPS untuk mengontrol tingkat sparsity. Eksperimen dilakukan pada MS MARCO passage ranking (8,8 juta dokumen) dan TREC DL 2019. Metrik evaluasi yang digunakan meliputi MRR@10, Recall@1000, dan nDCG@10. Sebagai pembandingan, model dasar yang digunakan adalah BM25, *dense bi-encoder* (ANCE dan TAS-B), serta berbagai metode sparse lainnya.

Eksperimen menunjukkan perbedaan performa yang jelas antara SPLADE-max dan BM25. Saat diuji pada MS MARCO dev set, SPLADE-max memperoleh skor MRR@10 sebesar 34,5 dan Recall@1000 sebesar 96,5. Pencapaian ini menunjukkan peningkatan akurasi sebesar 87% dan 13% dibandingkan dengan arsitektur BM25,

yang hanya mencapai $MRR@10$ sebesar 18,4 dan $R@1000$ sebesar 85,3. Bukti efektivitas SPLADE-max juga terlihat pada uji TREC DL 2019, di mana model ini meraih $nDCG@10$ sebesar 67,6, mengalahkan BM25 sebesar 50,6 dengan peningkatan performa sebesar 34%. Penelitian ini menegaskan secara jelas bahwa metode berbasis kata kunci memiliki keterbatasan dalam memahami konteks semantik dan menunjukkan bahwa model transformer ringan (DistilBERT 66M parameter) dapat mencapai performa yang kompetitif dibandingkan dengan model yang lebih besar [2].

2.2.4 Transformers-Based Information Retrieval

Bhopale dan Tiwari (2024) membangun alur *information retrieval* dengan memanfaatkan model transformer untuk merepresentasikan teks secara kontekstual. Sistem mereka menggunakan *Sentence-BERT* (SBERT) dengan arsitektur *bi-encoder*. Pendekatan ini memproses kueri dan dokumen secara terpisah, namun keduanya dipetakan ke dalam ruang vektor yang sama sehingga tingkat kemiripannya dapat dibandingkan.

Pendekatan peringkasan teks berbasis BERT diusulkan sebagai solusi atas kendala panjang maksimal sekuens dokumen. Guna mengoptimalkan ruang lingkup pencarian, diterapkan mekanisme ekspansi kueri yang bersandar pada nilai embedding frasa. Hasil perolehan dari tahap *retrieval* awal ini selanjutnya difilter dan diurutkan ulang menggunakan *cross-encoder* BERT. Tahapan *re-ranking* ini menjadi fase krusial untuk memetakan benang merah interaksi antara kueri dan dokumen secara lebih presisi dan mendalam.

Evaluasi dilakukan pada dua dataset standar: TREC-CDS-2014 dan OHSUMED. Hasil eksperimen membuktikan bahwa pendekatan berbasis transformer yang diusulkan dapat memberikan performa pencarian yang lebih baik dibandingkan dengan metode pencarian konvensional yang hanya mencocokkan kata kunci. Framework berhasil mengatasi keterbatasan *sequence length* sambil mempertahankan fitur deskriptif penting dari dokumen [6].

2.2.5 Multimodal Document Retrieval

Chen dkk. (2025) membangun model MDKG-RL (*Multimodal Document Knowledge Graph with Reinforcement Learning*) untuk menangani dokumen multimodal. Sistem ini menggunakan tiga jenis transformer: BERT untuk teks, *Vision*

Transformer (ViT) untuk gambar, dan *Audio Transformer* untuk audio. Ketiga model tersebut di-fine-tune dengan data arsip dari domain tertentu.

Arsitektur yang dikembangkan menggabungkan ChromaDB berbasis indeks HNSW untuk manajemen vektor dengan GraphSAGE sebagai mesin pengolah logika pada *knowledge graph*. Penajaman hasil pencarian dilakukan melalui algoritma PPO dari ranah *deep reinforcement learning* yang berfungsi sebagai modul optimasi pencarian. Melalui skema ini, mekanisme pencarian tidak bersifat statis, melainkan dapat menyesuaikan diri dengan preferensi dan masukan pengguna untuk menghasilkan hasil yang lebih relevan.

Hasil evaluasi pada dataset ICDAR 2023 yang berisi 100.000 dokumen multimodal membuktikan performa yang baik, dengan nilai MRR mencapai 0,85 dan NDCG mencapai 0,88. Sistem ini mampu meningkatkan performa hingga 13,3% dibandingkan baseline BERT-GNN, dengan waktu respons hanya 0,21 detik dan akurasi entity linking mencapai 92,4%. Ketika diuji pada dataset AIDA Corpus, sistem bahkan mencatat performa yang lebih tinggi, dengan MRR 0,88 dan NDCG 0,90. Penelitian ini memberikan wawasan penting tentang bagaimana pendekatan *multimodal dan reinforcement learning* dapat diterapkan untuk meningkatkan sistem manajemen dan retrieval dokumen [15].

Tabel 1. Perbandingan Penelitian Terdahulu dengan Penelitian Sekarang

No	Peneliti	Tahun	Judul	Metode	Hasil
1.	M. Safar et al.	2025	<i>Recommendation systems with LLM-based semantic embeddings and FAISS similarity search</i>	Memfaatkan <i>Large Language Model</i> tipe <i>Sentence Transformers</i> untuk menghasilkan representasi embedding semantik. Agar pencarian pada skala raksasa tetap ringan, pengindeksan data sepenuhnya diserahkan kepada arsitektur FAISS yang berbekal algoritma HNSW.	Skalabilitas sistem terbukti sangat baik dengan latensi di bawah 100 milidetik saat mengolah jutaan data. Penerapan FAISS sukses menghemat daya komputasi hingga 80% dibandingkan pendekatan <i>brute-force</i> , tanpa mengorbankan kualitas temu kembali (skor <i>recall</i> tetap awet di atas 95%).
2.	T. Formal, C. Lassance, B. Piwowarski, S. Clinchant	2024	<i>Towards Effective and Efficient Sparse Neural Information Retrieval</i>	Merancang arsitektur SPLADE dengan backbone DistilBERT yang dipadukan dengan MLM head untuk mengekstrak representasi teks yang ringan (<i>sparse</i>). Proses pelatihannya menyeimbangkan antara optimasi <i>ranking loss</i> dan regularisasi FLOPS.	Kinerja SPLADE-max sukses membungkam metode <i>keyword-based</i> (BM25) di korpus MS MARCO dengan raihan MRR@10 (34,5) dan Recall@1000 (96,5), alias meroket tajam hingga 87% untuk akurasi MRR. Tren positif ini berlanjut pada uji TREC DL 2019 dengan lonjakan skor nDCG sebesar 34%.

3.	Bhopale, Tiwari	2024	<i>Transformer-based Information Retrieval Framework</i>	Menerapkan <i>Sentence-BERT</i> berkonsep <i>bi-encoder</i> yang dikawinkan dengan fitur pemampatan teks untuk mengatasi keterbatasan panjang dokumen. Jangkauan kueri diperlebar melalui <i>phrase embedding</i> , lalu daftar hasil diurutkan ulang secara presisi oleh <i>cross-encoder</i> BERT.	Skema pemrosesan bertingkat ini sanggup melampaui akurasi metode ekstraksi kata kunci tradisional, khususnya saat sistem divalidasi dan dievaluasi menggunakan kumpulan data TREC-CDS-2014 maupun OHSUMED.
4.	Y. Chen et al.	2025	<i>Optimizing document management and retrieval with multimodal transformers and knowledge graphs</i>	Mengawinkan tiga varian <i>transformer</i> sekaligus (teks, gambar, dan audio) menjadi satu model MDKG-RL yang utuh. Seluruh vektor ditampung di ChromaDB, dilogikakan lewat GraphSAGE, lalu proses temu kembalinya dipoles secara dinamis oleh algoritma <i>Reinforcement Learning</i> (PPO).	Mengamankan skor MRR 0,85 pada data ICDAR 2023 dengan latensi yang sangat singkat (0,21 detik). Catatan ini merepresentasikan lompatan kualitas <i>retrieval</i> sebesar 13,3% dibandingkan dengan model dasar BERT-GNN. Performa korpus AIDA bahkan lebih solid dengan NDCG menyentuh 0,90.

5.	A. P. Putra, D. P. S. Putri, A. K. A. C. Wiranatha	2025	<i>Scientific Paper Recommendation System: Application of Sentence Transformers and Cosine Similarity Using arXiv Data</i>	Membangun mesin rekomendasi jurnal dengan menyandarkan komputasinya pada arsitektur all-MiniLM-L6-v2. Analisis kemiripan semantik antara belasan ribu artikel arXiv dieksekusi menggunakan fungsi kalkulasi <i>cosine similarity</i> .	Cukup mengejutkan bahwa pemrosesan teks <i>Introduction</i> mentah (tanpa <i>preprocessing</i>) justru menghasilkan skor tertinggi dengan NDCG 0,7590. Dari sisi kepuasan pengguna, 95,5% partisipan merasa sangat terbantu oleh akurasi dokumen yang disajikan.
6.	Penelitian Sekarang	2026	<i>MiniLM-RAG: Sistem Pencarian Semantik Untuk Arsip Digital Perguruan Tinggi</i>	Penelitian ini menerapkan arsitektur <i>Retrieval-Augmented Generation</i> (RAG) melalui tiga tahapan komputasi utama. Tahap pertama diawali dengan pencarian semantik menggunakan model <i>bi-encoder</i> , yaitu sentence transformer/paraphrase-multilingual-MiniLM-L12-v2 yang difine-tune pada korpus arsip dan diindeks ke dalam basis data ChromaDB menggunakan algoritma HNSW. Selanjutnya, dokumen kandidat diurutkan ulang (<i>reranking</i>) oleh	Integrasi arsitektur RAG multi-tahap ini diproyeksikan mampu meningkatkan akurasi dan efisiensi pencarian informasi secara signifikan melampaui pencarian semantik konvensional, yang ditargetkan melalui peningkatan skor metrik <i>Mean Reciprocal Rank</i> (MRR) dan <i>Normalized Discounted Cumulative Gain</i> (NDCG) berkat penerapan <i>Cross-Encoder</i> serta pembobotan hibrida. Pada tahap generasi, pelibatan LLM diharapkan mampu menyajikan teks jawaban yang deskriptif, presisi, dan mengurangi

				model <i>Cross-Encoder</i> melalui perhitungan <i>hybrid scoring</i> dan penyaringan leksikal berbasis Sastrawi untuk menekan angka <i>false positive</i>. Pada tahap akhir, teks jawaban disintesis menggunakan <i>Large Language Model</i> (Gemma-2B atau Llama-3B) yang dibatasi oleh instruksi (<i>prompt</i>) yang ketat agar informasi yang dihasilkan murni bersumber dari dokumen yang relevan, sehingga mengurangi terjadinya halusinasi data.	halusinasi. Secara teknis, seluruh <i>pipeline</i> komputasi ini dirancang untuk mempertahankan tingkat latensi <i>end-to-end</i> yang rendah, sehingga sistem dinilai layak dan siap diimplementasikan sebagai solusi tata kelola arsip digital di lingkungan perguruan tinggi.
--	--	--	--	--	---

BAB III

METODOLOGI PENELITIAN

3.1 Waktu Penelitian

Adapun jadwal penelitian sebagai berikut seperti pada Tabel 2 Di bawah ini.

Tabel 2. Waktu Penelitian

No	Kegiatan	Bulan						
		1	2	3	4	5	6	7
1	Ekstraksi dokumen dan penyusunan dataset							
2	Penyusunan dataset query uji							
3	Penyusunan dataset query uji							
4	Pra-pemrosesan data dokumen dan query							
5	Pembentukan embedding menggunakan model <i>Sentence Transformer</i> MiniLM							
6	Implementasi pengukuran kemiripan dan pemeringkatan dokumen							
7	Pengujian sistem semantic search							
8	Evaluasi kinerja sistem (Precision@k, Recall@k, Accuracy@k)							
9	Penyusunan laporan skripsi							

3.2 Alat dan Bahan Penelitian

Kebutuhan sistem yang digunakan dalam pembuatan dan uji coba penelitian ini terbagi menjadi 2 yaitu:

1. Perangkat Keras:

- a. Laptop Lenovo LOQ 15IRX9, Intel Core I5 (Gen-13), NVIDIA GeForce RTX 3050 6GB, RAM 20 GB DDR 5, SSD 943 GB

2. Perangkat Lunak:


- a. Framework pembelajaran mesin Pytorch 2.0+
- b. Bahasa pemrograman Python 3.10+
- c. OS Windows 11
- d. Pycharm / VS Code (IDE)
- e. Microsoft Office 2021
- f. Whimsical
- g. Library pendukung NLP: Sentence-Transformers, Transformers, NumPy, SciPy, Scikit-Learn, PyPDF, dan Python-Docx
- h. Mendeley Desktop
- i. Git

3.3 Model Penelitian

Penelitian ini menggunakan metode rekayasa sistem eksperimental (R&D) dengan pendekatan pengembangan arsitektur kecerdasan buatan. Metode ini dipilih karena penelitian secara spesifik bertujuan untuk merancang, mengimplementasikan, dan mengevaluasi sebuah produk berupa sistem pencarian semantik (*semantic search*) yang terintegrasi dengan *Retrieval-Augmented Generation* (RAG) untuk mengoptimalkan pengelolaan arsip akademik di perguruan tinggi [3], [6]. Dalam proses pengembangannya, digunakan arsitektur sistem yang terstruktur dan diklasifikasikan menjadi tiga modul operasional utama, yaitu *Offline Indexing*, *Online Retrieval*, dan *RAG Agent*. Model pengembangan ini mengarahkan rekayasa perangkat lunak melalui tahapan teknis yang saling berkesinambungan, dimulai dari fase pengumpulan dan prapemrosesan data korpus, pelatihan model vektorisasi teks (*sentence transformer* MiniLM *fine-tuned*), pengindeksan vektor pada ChromaDB, eksekusi pencarian dan pemeringkatan ulang dengan cross-encoder dan bi-encoder (*hybrid reranking*) [16], hingga pada tahap pengujian menyeluruh menggunakan metrik *Information Retrieval* standar [17] dan kerangka evaluasi RAGAS [14].


3.4 Tahapan Penelitian

Pada penelitian ini akan melakukan beberapa tahapan yaitu identifikasi masalah, studi literatur, pengumpulan dan persiapan dataset, pra-pemrosesan dan pembagian data, pemilihan dan perancangan model, proses pelatihan model, evaluasi model, analisis dan pembahasan, penarikan kesimpulan dan saran seperti pada Gambar 1.



Gambar 1. Tahapan Penelitian

3.5 Arsitektur Sistem



Gambar 2. Arsitektur Sistem

3.5.1 Pengumpulan, Pemrosesan, dan Augmentasi Data

Tahap awal arsitektur sistem pada Gambar 2 dimulai dengan pengumpulan dokumen arsip kampus dalam format digital (seperti PDF atau Word). Dokumen mentah kemudian diekstraksi teksnya menjadi format JSONL (*JSON Lines*) yang terstruktur, dengan memisahkan bagian Judul (*Title*) dan Isi (*Content*). Proses pembersihan data (*cleaning*) dilakukan untuk menghapus karakter non-ASCII, spasi berlebih, serta elemen *header/footer* yang tidak relevan. Tahapan *preprocessing* ini sangat krusial karena kualitas data input berpengaruh signifikan terhadap kualitas vektor yang dihasilkan [18], [19]. Untuk meningkatkan kecerdasan model, dilakukan tahap augmentasi data. Satu dokumen tidak hanya menghasilkan satu pasangan latih, melainkan dipecah menjadi beberapa variasi pasangan kueri dokumen sintetis, yaitu: pasangan [Judul, Isi], pasangan [Snippet 200 karakter awal, Judul], dan pasangan [Kata Kunci, Judul]. Hal ini bertujuan untuk melatih model agar dapat mengenali dan mempelajari kueri pengguna yang tidak lengkap atau ambigu [13].

3.5.2 Pelatihan Embedding Model (*Fine-Tuned Mini Language Model*)

Setelah dokumen melalui tahap pembersihan dan prapemrosesan, data tersebut diolah menggunakan arsitektur Sentence Transformer untuk diekstraksi menjadi representasi vektor. Pada tahap ini, sistem menggunakan model *Sentence Transformer/paraphrase-multilingual-MiniLM-L12-v2* yang berperan sebagai Bi-Encoder dan dilatih menggunakan dataset yang sudah dipersiapkan sebelumnya. Model ini bertugas mengubah setiap teks dari dokumen arsip menjadi representasi vektor berdimensi 384, dengan memanfaatkan mekanisme *self-attention* [6].

Secara matematis, mekanisme self-attention (khususnya *Scale Dot-Product Attention*) [10] yang menjadi fondasi dasar arsitektur Transformer dirumuskan sebagai berikut:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

Persamaan 1. Scale Dot-Product Attention

Pada Persamaan 1 matriks Q (*Query*), K (*Key*), dan V (*Value*) merupakan hasil transformasi dari setiap token (potongan kata) yang menjadi input model. Variabel dk menyatakan dimensi matriks Key, yang berfungsi sebagai faktor penskalaan untuk menjaga agar nilai gradien tidak menjadi terlalu besar selama proses pelatihan. Fungsi softmax kemudian digunakan untuk mengubah hasil perhitungan kemiripan (dot product) tersebut menjadi bobot probabilitas yang menunjukkan seberapa besar perhatian (atensi) suatu token terhadap token-token lain dalam satu kalimat, sehingga konteks semantiknya dapat dipahami secara lebih menyeluruh.

Setelah proses self-attention selesai, untuk mendapatkan vektor akhir yang mewakili satu dokumen (V_{doc}), sistem menerapkan teknik *Mean Pooling*. Caranya adalah dengan menghitung rata-rata dari seluruh vektor token (v_i) yang dihasilkan pada layer terakhir model *Transformer* [6]. Mekanisme perhitungannya dirumuskan sebagai berikut:

$$V_{doc} = \frac{1}{N} \sum_{i=1}^N v_i \quad (2)$$

Persamaan 2. Average Pooling

Pada Persamaan 2 di atas, variabel V_{doc} merupakan representasi vektor dari keseluruhan kalimat, variabel N adalah jumlah total token yang menyusun kalimat, dan v_i merupakan nilai vektor *embedding* untuk setiap token atau potongan kata.

Berdasarkan berbagai penelitian, metode penggabungan rata-rata seperti ini terbukti lebih efektif dalam menangkap dan merepresentasikan makna semantik suatu kalimat dibandingkan dengan pendekatan yang hanya mengandalkan satu token klasifikasi tunggal [20].

- a. **Strategi Input:** Karakteristik arsip administratif umumnya tersusun atas sekuens teks yang cukup panjang. Sistem mengambil langkah mitigasi melalui metode segmentasi (*chunking*) atau dengan memadukan elemen judul dan isi dokumen secara terstruktur. Implementasi strategi ini sangat penting untuk mencegah terjadinya pemotongan teks secara paksa, sehingga pemodelan tetap leluasa memahami konteks dokumen secara komprehensif baik pada level lokal maupun global tanpa melebihi batas toleransi kapasitas token [14], [21].
- b. **Output:** Rangkaian proses di atas akan bermuara pada terbentuknya sekumpulan representasi vektor secara massal (*corpus embeddings*). Guna menjamin efisiensi dan kecepatan waktu respons, seluruh hasil vektorisasi ini secara otomatis diindeks dan disimpan ke dalam basis data vektor (*vector database*) yang dirancang khusus untuk memfasilitasi pencarian semantik berkecepatan tinggi [6].

3.5.3 Penyimpanan dan pengindeksian Vektor (*Vector Indexing*)

Sebagai pengganti metode penyimpanan statis tradisional, representasi *corpus embeddings* beserta seluruh atribut metadata disimpan secara terpusat dalam basis data vektor, yaitu ChromaDB. Sistem ini dibangun menggunakan arsitektur indeksasi berdasarkan algoritma *Hierarchical Navigable Small World* (HNSW) [22] dengan metrik *cosine similarity*. Struktur HNSW sangat penting karena mampu mendukung pencarian (*query*) berkecepatan tinggi pada ruang vektor berdimensi tinggi. Pendekatan operasional ini juga menawarkan fleksibilitas tinggi untuk memperbarui data secara dinamis, seperti penambahan arsip baru atau penghapusan dokumen usang, tanpa perlu melakukan rekomputasi atau reindeksasi seluruh dataset [11].

Pemilihan ChromaDB sebagai sistem manajemen basis data vektor dalam penelitian ini tidak hanya didasarkan pada kapabilitas algoritma HNSW, melainkan juga pada karakteristik data arsip perguruan tinggi yang relatif statis dan menuntut waktu respons pencarian yang cepat. Berdasarkan studi komparatif performa basis data vektor oleh Abidin dan Engel (2025)[12], ChromaDB terbukti memberikan latensi

kueri yang konsisten dan rendah (*highly consistent, low query latency*).

Meskipun penelitian tersebut mencatat adanya pemborosan ruang penyimpanan dan pelambatan pada proses penambahan data berskala sangat besar, Abidin dan Engel (2025) menyimpulkan bahwa ChromaDB adalah arsitektur yang ideal untuk aplikasi yang membutuhkan terhadap latensi yang rendah (*latency-critical applications*) yang memiliki ekosistem data statis[12]. Karakteristik ini sesuai dengan kebutuhan arsitektur kearsipan perguruan tinggi pada penelitian ini, di mana penambahan dokumen seperti Surat Keputusan (SK) dan Standar Operasional Prosedur (SOP) tidak terjadi secara besar-besaran setiap detik. Sebaliknya, sistem ini memanfaatkan keunggulan kecepatan kueri ChromaDB untuk meminimalkan beban waktu pada tahap pencarian vektor, sehingga efisiensi latensi *end-to-end* pada *pipeline Retrieval-Augmented Generation* (RAG) tetap terjaga.

3.5.4 Pemrosesan Kueri (*Query Processing*)

Pada tahap ini, setiap instruksi input dari pengguna akan melewati proses prapemrosesan teks yang mirip dengan pembersihan pada korpus dokumen. Selanjutnya, kueri diubah menjadi representasi numerik (*query embedding*) dengan *self-attention* menggunakan model MiniLM *fine-tuned* [6]. Penggunaan model tunggal ini sangat penting untuk memastikan konsistensi dalam perhitungan sistem. Dengan pendekatan ini, sistem menjamin bahwa maksud kueri pengguna dan dokumen dalam korpus diproyeksikan secara bersamaan ke dalam ruang laten semantik yang saling terkait [17]. Keselarasan dimensi pemetaan dalam ruang vektor menjadi dasar utama bagi operasi mesin basis data ChromaDB dalam menjalankan proses pencocokan dan pengambilan kembali informasi secara lengkap [23].

3.5.5 Perhitungan Kemiripan (*Similarity Calculation*)

Pada tahap ini, sistem melakukan penghitungan metrik untuk menilai seberapa dekat representasi vektor kueri pengguna dengan kumpulan vektor dokumen yang tersimpan dalam basis data. Pendekatan yang digunakan adalah *Cosine Similarity* [8], [24], yaitu metode pengukuran matematis yang didasarkan pada sudut kosinus antara dua vektor. Secara spesifik, komputasi tersebut dirumuskan sebagai berikut:

$$\text{similarity}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \quad (3)$$

Persamaan 3. Cosine Similarity

Berdasarkan Persamaan 3 di atas, A merepresentasikan vektor kueri masukan,

sementara B merupakan vektor dokumen. Semakin hasil komputasi mendekati probabilitas nilai 1, maka orientasi kedua vektor tersebut diindikasikan semakin selaras, yang merepresentasikan korelasi serta relevansi semantik yang sangat tinggi antarteks.

Implementasi algoritma Cosine Similarity dalam arsitektur ini didasarkan pada ketahanannya yang terbukti saat digunakan untuk memetakan korelasi dalam ruang vektor berdimensi besar. Dibandingkan dengan metode pengukuran jarak lurus konvensional (seperti jarak Euclidean), algoritma kosinus dianggap lebih unggul karena perhitungannya sepenuhnya berfokus pada arah orientasi vektor tanpa terpengaruh oleh perbedaan atau variasi panjang dokumen.

3.5.6 Pemeringkatan dan Penyajian Hasil (*Ranking & Retrieval*)

Hasil matematis dari komputasi metrik kemiripan selanjutnya didistribusikan ke dalam mekanisme pemeringkatan, di mana seluruh dokumen dalam korpus diurutkan secara menurun berdasarkan skor tertinggi hingga terendah. Pada tahap ini, algoritma sistem diarahkan untuk memfilter dan mengekstraksi sejumlah dokumen. Dokumen yang berada di posisi teratas (*Top-k retrieval*) menjadi representasi literatur dengan relevansi tertinggi yang akan disajikan kepada pengguna. Implementasi arsitektur pencarian berbasis semantik ini menawarkan keunggulan performa yang signifikan. Sistem mampu menampilkan dokumen yang secara makna sangat berkorelasi, meskipun kueri yang dikonstruksi pengguna tidak secara langsung memuat kata kunci ekuivalen (*exact keyword match*) terhadap isi dokumen [17], [23].

3.5.7 Evaluasi Model Embedding (*Embedding Model Evaluation*)

Sebagai tahap akhir dalam pengembangan arsitektur semantic search, subsistem evaluasi dibuat untuk memastikan kualitas hasil pencarian informasi. Pengujian ini dilakukan dengan membandingkan urutan dokumen yang dihasilkan sistem dengan data referensi absolut (*ground truth*) yang telah ditentukan sebelumnya. Pengukuran kinerja mengikuti standar evaluasi Information Retrieval (IR) dengan menggunakan berbagai metrik berikut:

a. Accuracy@k

Metrik ini menghitung persentase kueri di mana setidaknya satu dokumen yang relevan berhasil diekstraksi pada kelompok k -teratas (*Top-k*):

$$Accuracy@k = \frac{1}{|Q|} \sum_{i=1}^{|Q|} I_i(k) \quad (3)$$

Persamaan 4. Accuracy Top-k

Pada Persamaan 4, $|Q|$ Merepresentasikan akumulasi kueri pengujian. Variabel $I_i(k)$ bertindak sebagai fungsi indikator biner, yang akan bernilai 1 apabila terdapat minimal satu dokumen target pada urutan k -teratas untuk kueri ke- i , dan mengembalikan nilai 0 jika tidak ada [25].

b. Precision@k

Berfungsi untuk mengukur presisi dokumen yang relevan di dalam himpunan k -teratas:

$$Precision@k = \frac{|Retrieved_k \cap Relevant|}{k} \quad (4)$$

Persamaan 5. Precision Top-k

Kondisi $Retrieved_k$ mendefinisikan kelompok dokumen pada peringkat 1 hingga k , sedangkan $Relevant$ merupakan himpunan total dokumen relevan untuk kueri terkait. Nilai k merujuk pada batas evaluasi dokumen, misalnya 10 urutan teratas untuk $Precision@10$ [8].

c. Recall@k

Metrik ini mengukur seberapa baik sistem dapat mengambil semua dokumen relevan dari basis data:

$$Recall@k = \frac{|Retrieved_k \cap Relevant|}{|Relevant|} \quad (6)$$

Persamaan 6. Recall Top-k

Bagian pembilang dalam Persamaan 6 sama dengan rumusan metrik *Precision*, yaitu irisan antara dokumen yang diekstrak dan dokumen yang relevan. Sementara itu, penyebut mewakili jumlah total dokumen yang relevan terhadap kueri uji secara keseluruhan [3].

d. Mean Reciprocal Rank (MRR)

MRR digunakan untuk menilai seberapa cepat dan seberapa akurat sistem dalam menemukan dokumen target pertama. Semakin tinggi skor, semakin menunjukkan bahwa model memiliki kemampuan yang lebih baik dalam menempatkan jawaban yang paling tepat di posisi teratas:

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i} \quad (7)$$

Persamaan 7. Mean Reciprocal Rank

Dalam Persamaan 7 ini, $|Q|$ adalah total kueri dan $rank_i$ merupakan posisi peringkat dari dokumen relevan pertama untuk kueri ke- i . Apabila tidak ada satupun dokumen target yang berhasil diidentifikasi, maka representasi nilai $\frac{1}{rank_i}$ dikonversi menjadi 0 [8], [15].

e. *Mean Average Precision (MAP)*

Metrik ini melakukan kalkulasi rata-rata *Precision* secara kumulatif pada setiap posisi di mana dokumen yang relevan berhasil ditemukan:

$$MAP = \frac{1}{|Q|} \sum_{q=1}^{|Q|} AP(q) \quad (8)$$

Persamaan 8. Mean Average Precision

Adapun nilai *Average Precision* (AP) untuk kueri tunggal diformulasikan sebagai:

$$AP = \frac{1}{m} \sum_{k=1}^n (Precision@k \times rel(k)) \quad (9)$$

Persamaan 9. Average Precision

Di Persamaan 9, m adalah total dokumen yang bersesuaian dengan kueri, n menunjukkan jumlah dokumen yang ditemukan, dan $rel(k)$ berperan sebagai fungsi diskrit yang bernilai 1 jika dokumen pada indeks ke- k valid, serta 0 jika salah. Mekanisme ini memastikan bahwa presisi hanya dihitung pada titik persimpangan di mana dokumen relevan terdeteksi [8].

f. *Normalized Discounted Cumulative Gain (NDCG)*

NDCG [3] bertugas untuk mengevaluasi kualitas pemeringkatan secara menyeluruh dengan memberikan penalti matematis jika dokumen relevan ditempatkan di posisi bawah, dan memberikan bobot lebih tinggi jika dokumen tersebut berada di posisi atas (Top- k):

$$NDCG_k = \frac{DCG_k}{IDCG_k}, \text{ dimana } DCG_k = \sum_{i=1}^k \frac{rel_i}{\log_2(i+1)} \quad (10)$$

Persamaan 10. Normalized Discounted Cumulative Gain

Variabel rel_i pada Persamaan 10 menunjukkan skor relevansi dokumen pada indeks ke- i , dan $IDCG_k$ adalah proyeksi nilai DCG_k Paling ideal apabila urutan dokumen tersusun sempurna dari skor tertinggi hingga terendah. Secara teknis, implementasi ini melibatkan ekosistem *open-source Hugging Face* [16].

3.5.8 Pemeringkatan Ulang Kontekstual (*Cross-Encoder Reranking*)

Untuk menutupi kelemahan arsitektur *Bi-Encoder* dalam menangkap interaksi kata secara langsung antara kueri pengguna dan dokumen, sistem menggunakan mekanisme pemeringkatan ulang berbasis *Cross-Encoder* (multilingual-mmrcmMiniLMv2). Rancangan ini menganalisis pasangan kueri (q) dan dokumen (d) secara bersamaan melalui komputasi *cross-attention* untuk mencapai tingkat relevansi yang jauh lebih mendekati jarak nilai kemiripan [6], [26]. Tahap ini mengimplementasikan skema penilaian hibrida (*hybrid scoring*) yang menggabungkan skor metrik jarak *Bi-Encoder* dengan probabilitas semantik *Cross-Encoder*. Selain itu, sistem juga menerapkan mekanisme penalti leksikal (*lexical penalty*) menggunakan algoritma *fuzzy keyword matching* dengan *stopword* Sastrawi untuk menurunkan skor dokumen yang tidak memuat kata kunci esensial. Komputasi skor akhir dirumuskan sebagai berikut:

$$Score_{hybrid} = (\alpha \cdot Score_{BE}) + (\beta \cdot Score_{CE}) - Penalty_{lexical} \quad (11)$$

Persamaan 11. Hybrid Scoring Function

Pada Persamaan 11 tersebut, variabel $Score_{BE}$ merepresentasikan metrik kemiripan dokumen yang dihasilkan pada tahap pencarian awal oleh arsitektur *Bi-Encoder*, sedangkan $Score_{CE}$ adalah skor probabilitas relevansi kontekstual yang dikomputasi oleh *Cross-Encoder*. Konstanta α (0,6) dan β (0,4) ditetapkan sebagai parameter penyeimbang bobot untuk mengatur proporsi pengaruh dari hasil nilai kedua model tersebut.

Adapun $Penalty_{lexical}$ berfungsi sebagai nilai pengurangan skor (penalti) berbasis pencocokan leksikal. Hukuman matematis ini secara dinamis akan mengevaluasi kehadiran kata kunci dan langsung memotong skor akhir apabila rasio ketepatan kata kunci di dalam dokumen (*match ratio*) kurang dari batas minimal

toleransi 0,25 (25%). Rangkaian perhitungan berlapis ini, yang dipadukan dengan batas minimum (*threshold*) skor 0,20, menjamin bahwa sistem hanya akan meneruskan dokumen arsip yang benar-benar relevan untuk diproses lebih lanjut oleh model bahasa generatif (LLM).

3.5.9 Perluasan Konteks dan Rekayasa Prompt (*Context Enrichment & Prompt Engineering*)

Dokumen relevan hasil tahapan pemeringkatan akan diekstraksi untuk menghindari pelanggaran batas kapasitas memori pada LLM (*context window limit*) [27]. Teks pendukung tersebut kemudian disusun sebagai fondasi pengetahuan eksternal dalam template prompt. Mekanisme rekayasa instruksi ini dirancang dengan pembatas yang sangat ketat untuk mengurangi kemungkinan halusinasi, dengan memaksa model untuk berfokus pada penalaran temporal [14], menegaskan pentingnya menoleransi kesamaan semantik, seperti penggunaan sinonim kualifikasi, serta mewajibkan pencantuman referensi legal secara eksplisit, misalnya nomor surat keputusan.

3.5.10 Pembentukan Respons RAG (*LLM Generation / Agentic RAG*)

Respons hasil akhir dilakukan dengan mengirimkan kueri pengguna dan prompt konteks lengkap kepada agen utama LLM. Untuk menjaga kerahasiaan data arsip perguruan tinggi, seluruh proses komputasi dijalankan secara lokal (*local deployment*) menggunakan mesin inferensi Ollama, tanpa melibatkan API pihak ketiga. Model bahasa yang didukung termasuk varian yang hemat sumber daya seperti Llama 3.2 (3B), Gemma 2 (2B), dan Qwen 2.5 (7B) [28], [29].

$$p_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (12)$$

Persamaan 12. Temperature-Scaled Softmax Function

Sebagai langkah untuk memastikan bahwa respons bersifat relevan dan faktual, pada Persamaan 12 nilai parameter suhu (T) direduksi agar mendekati 0. Penyesuaian konfigurasi ini mengubah distribusi probabilitas token (p_i) pada fungsi *softmax*, sehingga secara algoritma model akan selalu memilih struktur token dengan tingkat kepastian paling dominan [14].

3.5.11 Evaluasi Kualitas RAG (*RAGAS Framework*)

Karena metrik tradisional Information Retrieval tidak cukup untuk menilai kualitas model pembentuk kalimat, validasi sistem *end-to-end* dilakukan menggunakan

kerangka *LLM-as-a-Judge*. Qwen 2.5 berperan sebagai juri logika teks, sedangkan *paraphrase-multilingual-mpnet-base-v2* digunakan sebagai evaluator vektor. Penilaian performa dibagi menjadi tiga dimensi utama [14].

- a. ***Faithfulness* (Kesesuaian Fakta):** Mengukur tingkat keakuratan jawaban LLM yang sepenuhnya berdasarkan teks rujukan untuk mendeteksi keberadaan halusinasi informasi.
- b. ***Answer Relevancy* (Relevansi Jawaban):** Menghitung jarak kosinus proksimitas untuk mengukur seberapa akurat jawaban dalam menanggapi intensi kueri, sehingga mengurangi pengulangan kalimat.
- c. ***Context Precision* (Presisi Konteks):** Menilai performa retriever dalam mengutamakan dokumen referensi utama (*ground truth*) di posisi teratas sebelum dimasukkan ke dalam prompt sistem.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Penelitian

Bagian ini secara lengkap menjelaskan hasil pengujian dan implementasi arsitektur semantic search yang terintegrasi dengan arsitektur *Retrieval-Augmented Generation* (RAG) untuk manajemen arsip akademik di Universitas Darussalam Gontor. Pendekatan yang digunakan dalam penelitian ini merupakan eksperimen komputasional yang berfokus pada optimasi *Natural Language Processing* (NLP) dan peningkatan presisi sistem temu kembali informasi. Rangkaian hasil dan temuan yang disajikan mencakup seluruh siklus operasional sistem, termasuk output prapemrosesan dataset korpus arsip, evaluasi metrik *Information Retrieval* (IR) pada model embedding hasil *fine-tuning*, pengujian kualitas sintesis bahasa generatif berdasarkan metrik RAGAS, serta analisis efisiensi latensi komputasi *end-to-end* dalam lingkungan operasional.

4.1.1 Prapemrosesan Data

Tahap awal riset melibatkan kurasi dan ekstraksi arsip digital di Universitas Darussalam Gontor dan berhasil mengumpulkan 784 dokumen dalam struktur metadata berbasis JSON-Line (JSONL). Untuk memenuhi persyaratan peta ruang laten pada model *Information Retrieval* (IR), seluruh dokumen (100%) digunakan sebagai basis data untuk proses pelatihan (*fine-tuning*). Sebaliknya, proses validasi kinerja temu kembali informasi dilakukan dengan mengambil 20% sampel representatif dari total korpus yang dipisahkan secara khusus untuk data uji.

Strategi efisiensi performa komputasi diterapkan dengan mengurangi dimensi fitur input. Sistem hanya memilih tiga entitas utama, yaitu judul, isi dokumen, dan kata kunci. Selanjutnya, *maximum sequence length* disetel pada batas 384 token. Penyesuaian ini sangat ideal, bahwasanya rata-rata panjang dokumen akademik di institusi terkait sekitar 156 token. Rentang token yang dipilih ini memastikan makna semantik tetap utuh dan mencegah kehilangan konteks penting karena proses pemangkasan teks [30].

Tabel 3. Hasil Distribusi dan Premrosesan Dataset

Kriteria	Nilai / Spesifikasi
Total Dokumen Korpus	784 Dokumen
Distribusi Data Latih	784 Dokumen (100% Korpus)
Distribusi Data uji	157 Dokumen (Sampel 20% IR)
Dimensi Fitur Ekstraksi	Judul, Konten, Kata Kunci

4.1.2 Pelatihan Model Semantik (*Fine-Tuned*) dan Analisis Komparasi

Untuk menentukan arsitektur jaringan saraf tiruan yang paling optimal dalam domain kearsipan akademik, penelitian ini melakukan tahap fine-tuning melalui perbandingan tiga skenario pemodelan eksperimental. Ketiga varian tersebut meliputi: (1) versi murni *Sentence Transformer/paraphrase-multilingual-MiniLM-L12-v2* fine-tuned tanpa augmentasi data (baseline), (2) arsitektur SBERT berskala besar, yaitu *paraphrase-multilingual-mpnet-base-v2* fine-tuned, dan (3) model *Sentence Transformer* MiniLM dengan dataset sintesis (Boosted Model) yang ditambahkan sebanyak 2.352 sampel data sintetik. Seluruh parameter komputasi penting yang digunakan dalam skenario model optimal (model ketiga) dirangkum secara lengkap pada Tabel 4 berikut.

Tabel 4. Parameter Pelatihan Model MiniLM

Parameter/Konfigurasi	Spesifikasi/Nilai
Model Dasar	<i>Sentence-Transformer/Paraphrase-multilingual-MiniLM-L12-v2</i>
Jumlah data Latih	2.352 sampel (Augmentasi)
Fungsi Objektif (<i>Loss</i>)	<i>Multiple Negatives Ranking Loss</i> (MNRL)
<i>Strategi Pooling</i>	Mean Tokens Pooling
<i>Epoch / Batch Size / Seed</i>	10 / 16 / 42
Optimasi	AMP, 10% <i>Warmup Steps</i>
Konvergensi Loss	0,40 → 0,001
Durasi Pelatihan	3, 18 Menit

Fase pra-pelatihan untuk model teraugmentasi ini dilakukan dengan 10 epoch dan batch size 16, menggunakan akselerasi GPU dengan protokol *Automatic Mixed Precision* (AMP) untuk menghemat VRAM. Sesuai tabel, fungsi objektifnya adalah *Multiple Negatives Ranking Loss* (MNRL)[5], [31] yang dipadukan dengan algoritma *Mean Tokens Pooling*. Kombinasi matematis ini membantu memperkecil jarak antarvektor yang bermakna sama di ruang laten. Untuk menjaga stabilitas nilai koreksi pada fase awal, mekanisme *warmup steps* dengan rasio 10% diaktifkan. Konfigurasi mutakhir ini berhasil membawa model ke titik konvergensi yang sangat tajam, yang terlihat secara kuantitatif dari penurunan skor metrik loss dari 0,40 menjadi 0,001 dalam waktu komputasi 3,18 menit, serta memastikan model bebas dari kecenderungan overfitting.

4.2 Hasil Evaluasi Arsitektur Sistem

Pengujian sistem pencarian semantik dan *Retrieval-Augmented Generation* (RAG) dilakukan secara bertahap dan terstruktur sesuai dengan alur metodologi penelitian. Evaluasi ini terbagi menjadi tiga fase utama: (1) validasi model embedding (*Sentence Transformer* MiniLM pre-trained, fine-tuned, fine-tuned dengan augmentasi data sintetis, serta MPNet pre-trained dan fine-tuned) menggunakan metrik IR berbasis peringkat, (2) pengujian kualitas LLM dengan framework *Retrieval-Augmented Generation Assessment* (RAGAS) dan pendekatan *LLM-as-a-Judge*, serta (3) analisis efisiensi waktu komputasi (*latency*) pada arsitektur *client-server*. Prosedur pengujian terstruktur ini penting untuk memastikan bahwa semua arsip yang diekstraksi dan disajikan kepada LLM telah melalui verifikasi semantik yang ketat, sehingga jawaban akhir yang dihasilkan relevan, faktual, akurat, dan mengurangi halusinasi informasi (AI hallucination) sebelum sistem diterapkan pada infrastruktur kampus.

4.2.1 Hasil Evaluasi *Information Retrieval* (IR)


Validasi arsitektur Information Retrieval (IR) dilakukan melalui perbandingan lima skenario pemodelan vektor: arsitektur *Sentence-BERT paraphrase-multilingual-MiniLM-L12-v2* [5], [6] *Fine-tuned* dioptimalkan dengan data sintetis (*Boosted*), MiniLM versi *pre-trained* tanpa augmentasi (*Baseline*), model fine-tuned MiniLM tanpa data sintetis atau augmentasi, model berparameter besar berbasis *Sentence-BERT (paraphrase-multilingual-mpnet-base-v2)* pre-trained dan fine-tuned. Fokus utama pengujian ini adalah mengukur seberapa akurat sistem dalam menyaring dan mengekstraksi dokumen arsip yang memiliki kedekatan semantik dengan query pengguna [3]. Hasil kuantitatif dari metrik evaluasi ketiga model tersebut dirangkum secara lengkap pada Tabel 5.

Tabel 5. Hasil Evaluasi Information Retrieval

Metrik Evaluasi	MiniLM Pre-Trained	MiniLM Fine-Tuned Augmentasi	MiniLM Fine-Tuned	MPNet Pre-Trained	MPNet Fine-Tuned
Recall@1	0,6625	0,9231	0,9103	0,7070	0,9231
Recall@3	0,8217	0,9744	0,9744	0,8535	0,9744
Recall@5	0,8726	0,9936	0,9936	0,8980	0,9936
Recall@10	0,9045	1,0000	1,0000	0,9235	1,0000
Precision@1	0,6625	0,9231	0,9103	0,7070	0,9231
Precision@3	0,2849	0,3248	0,3248	0,2845	0,3248
Precision@5	0,1746	0,1987	0,1987	0,1797	0,1987
Precision@10	0,0905	0,1000	0,1000	0,0924	0,1000
NDCG@10	0,7868	0,9632	0,9593	0,8215	0,9561

MRR@10	0,7485	0,9511	0,9457	0,7879	0,9415
MAP@100	0,7519	0,9511	0,9457	0,7902	0,9415

Merujuk pada data di Tabel 5, ketiga arsitektur tersebut menunjukkan kualitas sistem pencarian informasi yang sangat optimal pada rentang eksplorasi yang lebih luas. Kesuksesan ini terbukti dari perolehan skor mutlak pada Recall@10 yang mendekati nilai 1 dan metrik Recall@5 (0,9936), yang memastikan bahwa dokumen



Gambar 3. Metrik Evaluasi Information Retrieval


sasaran selalu berhasil teridentifikasi dalam 10 hasil pencarian teratas. Di sisi lain, terlihat adanya penurunan nilai presisi yang drastis dari 0,92 menjadi 0,10 pada metrik Precision@10. Namun, hal ini merupakan konsekuensi logis dan wajar dalam pengujian pencarian pada domain tertutup (*closed-domain*). Mengingat jumlah arsip spesifik yang valid untuk satu kueri umumnya hanya 1 hingga 2 dokumen, perluasan pencarian (Top-*k*) secara matematis akan memperbesar angka pembagi sehingga menekan skor presisi akhir. Oleh karena itu, penurunan metrik ini sama sekali tidak mengindikasikan adanya disfungsi pada sistem.

Secara mendetail, performa model dalam perbandingan yang divisualisasikan pada Gambar 3 evaluasi sistem pencarian semantik sebenarnya menuntut pengukuran kualitas pemeringkatan dokumen, bukan hanya ketepatan klasifikasi biner. Maka dari itu, digunakan metrik *Accuracy* Top-*k* bersama *Normalized Discounted Cumulative Gain* (NDCG@*k*), *Mean Reciprocal Rank* (MRR@*k*), dan Precision@*k*. Akurasi konvensional dianggap gagal merepresentasikan performa karena dapat mengabaikan keberhasilan ketika dokumen target muncul pada posisi kedua. Sebaliknya, metrik Top-

k memberikan toleransi evaluasi yang lebih realistis. Kemampuan sistem untuk menampilkan dokumen yang relevan di posisi teratas sangat penting untuk menyajikan konteks yang tepat dalam arsitektur RAG. Sebagaimana didukung oleh referensi, metrik $MRR@k$ sangat cocok untuk mengukur posisi urutan dokumen relevan pertama, sementara $NDCG@k$ secara tepat menilai bobot seluruh peringkat [17].

Berdasarkan analisis pemeringkatan (Top-1) dari Tabel 5 dan Gambar 3, model *Sentence Transformer* MiniLM *fine-tuned* yang telah ditingkatkan dengan data augmentasi berhasil meraih kinerja terbaik. Arsitektur ini membukukan skor $NDCG@10$ sebesar 0,9632, $MRR@10$ sebesar 0,9511, serta $Precision@1$ sebesar 0,9231. Identiknya, perolehan nilai MRR dan MAP mengonfirmasi bahwa *Boosted Model* ini tidak sekadar akurat, melainkan juga sangat konsisten dalam menempatkan dokumen referensi utama pada peringkat 1. MiniLM standar menempati urutan kedua (MRR 0,9457), sementara model raksasa SBERT (MPNet) menghasilkan performa terlemah pada metrik Top-1 dengan perolehan MRR 0,9415 dan $NDCG$ 0,9561.

Lebih lanjut, jika dibandingkan dengan arsitektur dasar sebelum dilatih ulang pada domain spesifik, terlihat kesenjangan performa yang sangat signifikan. Model MPNet *pre-trained* hanya mampu mencatatkan skor MRR sebesar 0,7879 dan $NDCG$ 0,8215. Sementara itu, model MiniLM *pre-trained* (*baseline*) menghasilkan kinerja terlemah dari seluruh skenario pengujian dengan nilai MRR 0,7485 dan $NDCG$ 0,7868. Kesenjangan skor yang tajam antara kelompok *pre-trained* dan *fine-tuned* ini menegaskan bahwa penerapan *fine-tuning*, terutama yang dioptimalkan dengan augmentasi data sintetik, merupakan tahapan penting yang terbukti berdampak dalam meningkatkan kemampuan pemahaman semantik model untuk pencarian arsip spesifik (*closed-domain*).



Gambar 4. Nilai Efisiensi Model

Keunggulan komparatif ini memberikan dampak strategis yang semakin nyata seperti pada Gambar 4. Evaluasi tersebut membuktikan bahwa pendekatan rekayasa augmentasi data sintetik berkinerja sangat efektif dalam mempertajam kepekaan pemahaman model pemrosesan bahasa berskala kecil (*lightweight*) terhadap kueri yang bervariasi. Model *Sentence Transformer* MiniLM yang telah di-*fine-tune* dan di-augmentasi tidak hanya mengoptimalkan akurasi pencarian pada model berbobot rendah, tetapi pada saat yang sama juga menurunkan beban kerja perangkat keras dibandingkan model dengan parameter yang lebih besar. Hasil temuan ini membuktikan bahwa arsitektur tersebut merupakan solusi teknis yang optimal dan realistis untuk diimplementasikan dalam ekosistem infrastruktur kampus yang memiliki keterbatasan sumber daya komputasi.

4.2.2 Hasil Evaluasi Kualitas Jawaban LLM (*RAG-Assessment*)

Untuk mengukur kemampuan sistem dalam menghasilkan teks balasan, riset ini mengimplementasikan protokol evaluasi *Retrieval-Augmented Generation Assessment* (RAGAS). Skenario pengujian difokuskan untuk mengevaluasi kualitas luaran linguistik dari tiga varian *Large Language Model* (LLM) yaitu Llama 3.2 (3B), Gemma 2 (2B), serta Qwen 2.5 (7B) yang dioperasikan melalui 20 instrumen kueri uji untuk menyimulasikan interaksi nyata pada pencarian arsip kampus [14]. Akumulasi performa dari setiap model, lengkap dengan nilai standar deviasi untuk melihat tingkat kestabilannya pada Tabel 6 berikut.

Tabel 6. Hasil Evaluasi RAGAS Berdasarkan Model LLM

Model LLM	Faithfulness	Answer Relevancy	Context Precision	Overall Score
Llama 3.2 3B	$0,92 \pm 0,18$	$0,86 \pm 0,11$	$0,90 \pm 0,20$	0,893
Gemma 2 2B	$0,97 \pm 0,15$	$0,89 \pm 0,21$	$0,91 \pm 0,20$	0,923
Qwen 2.5 7B	$0,79 \pm 0,33$	$0,76 \pm 0,28$	$0,91 \pm 0,20$	0,820

Merujuk pada Tabel 6 nilai di atas nilai akhir (*Overall Score*) dikalkulasikan menggunakan pendekatan rata-rata harmonik (*Harmonic Mean*) dari tiga parameter esensial yang menyusunnya. Perhitungan matematis ini secara spesifik dipilih guna menjatuhkan penalti yang signifikan apabila sebuah model mengalami defisit skor pada salah satu metrik evaluasi [3]. Hasilnya, arsitektur Gemma 2 (2B) terbukti sukses mendominasi perbandingan nilai dengan skor tertinggi, yaitu 0,923. Keunggulan ini disebabkan oleh optimalnya dimensi *Faithfulness* (0,97) dan *Answer Relevancy* (0,89), yang menunjukkan kemampuan model tersebut dalam menjaga keberanan fakta sekaligus meminimalkan halusinasi dalam teks. Menyusul di peringkat kedua, Llama 3.2 (3B) menunjukkan stabilitas performa generatif yang cukup kompetitif (0,893).

Berbanding terbalik, Qwen 2.5 (7B) menghasilkan nilai akumulasi paling rendah (0,820). Penurunan kualitas ini berhubungan langsung dengan tingginya ketidakstabilan penyebaran data pada matriks *Faithfulness* yang mencapai angka 0,33. Tingkat perubahan yang drastis tersebut merupakan indikasi tidak stabilnya inferensi (*erroneous decoding*) yang didorong oleh bias pengetahuan bawaan (*parametric knowledge bias*) [32]. Kapasitas parameternya yang sangat besar memaksa Qwen 2.5 untuk lebih mengandalkan memori internal ketimbang bersandar pada dokumen referensi murni yang disuplai oleh sistem. Maka dari itu, dalam merespons deretan kueri pengujian, varian ini menjadi entitas yang paling berisiko menghasilkan informasi buatan atau halusinasi kecerdasan buatan (*AI hallucination*) [33].

4.2.3 Analisis Efisiensi Waktu Komputasi (*Latency Evaluation*)

Fase terakhir dalam tahap pengujian ini berfokus pada uji efisiensi waktu komputasi sistem saat dijalankan dan dievaluasi. Pengukuran efisiensi waktu atau latensi dilakukan menggunakan arsitektur *client-server* untuk merekam jejak durasi pemrosesan dari awal hingga akhir. Proses ini mencakup tahapan konversi kueri, kalkulasi pencarian vektor menggunakan ChromaDB, mekanisme pengurutan ulang hibrida, hingga tahap akhir yaitu pembuatan teks oleh *Large Language Model* (LLM) [34]. Secara spesifik, performa subsistem pencarian semantik (*semantic search*) pada alur API menunjukkan tingkat responsivitas yang sangat baik, dengan rentang durasi eksekusi hanya 2,07 hingga 2,36 detik per kueri. Rincian komparasi beban latensi dari masing-masing arsitektur LLM tersebut dapat dilihat secara detail pada Tabel 7.

Tabel 7. Distribusi Latensi Sistem (Rata-rata Per Kueri)

Model LLM	Llama 3.2 (3B)	Gemma 2 (2B)	Qwen 2.5 (7B)
Vector Search & Hybrid			
Reranking (API)	2,36 detik	2,22 detik	2,07 detik
Inferensi LLM	4,59 detik	3,85 detik	15,16 detik
Rata-rata Latency	6,95 detik	6,07 detik	17,22 detik

Berdasarkan analisis latensi komputasi pada Tabel 7, terlihat jelas bahwa tahap inferensi LLM menyebabkan pemrosesan waktu yang paling dominan, sehingga berpotensi menghasilkan hambatan performa. Sebagai contoh, percobaan model dengan kapasitas parameter masif seperti Qwen 2.5 (7B) membutuhkan durasi spesifik hingga 15,16 detik untuk mengeksekusi teks. Jeda waktu yang panjang dinilai kurang baik apabila diterapkan pada platform layanan arsip kampus yang mensyaratkan interaktivitas *real-time* dengan pengguna.

Sebagai solusi atas tingginya beban latensi tersebut, penggunaan LLM Gemma 2 (2B) menghasilkan efisiensi komputasi yang lebih optimal. Karena konfigurasi parameternya yang tergolong ringkas, model ini sanggup merangkai sintesis narasi hanya dalam 3,85 detik, sehingga secara jelas memangkas latensi total menjadi 6,07 detik. Bukti nyata ini membuktikan bahwa arsitektur RAG yang dijalankan oleh Gemma 2 (2B) merupakan titik keseimbangan komputasi yang paling proporsional, di mana ketajaman logika sintesis informasi berhasil diselaraskan dengan kecepatan respons sistem [35]. Keunggulan latensi total sebesar 6,07 detik pada Gemma 2 (2B) tersebut merupakan representasi dari arsitektur komputasi yang lebih ringan dan efisien jika dibandingkan dengan model LLM lainnya dalam pengujian.

Pada tahap penelusuran awal (*Vector Search & Hybrid Reranking* via API), ketiga model menunjukkan durasi pemrosesan yang relatif setara dan konsisten, yakni 2,22 detik untuk Gemma 2 (2B), 2,36 detik untuk Llama 3.2 (3B), dan 2,07 detik untuk Qwen 2.5 (7B). Namun, perbedaan waktu yang signifikan terlihat pada fase inferensi LLM, di mana Gemma 2 (2B) mencatatkan waktu generasi teks tercepat sebesar 3,85 detik, mengungguli Llama 3.2 (3B) yang memerlukan 4,59 detik (rata-rata latensi total 6,95 detik), serta jauh lebih efisien dibandingkan Qwen 2.5 (7B) yang membutuhkan durasi inferensi hingga 15,16 detik dengan total latensi mencapai 17,22 detik. Hal ini membuktikan bahwa ukuran parameter yang lebih ringkas pada Gemma 2 (2B) memberikan reduksi *computational overhead* yang signifikan pada proses inferensi *end-to-end*.

4.3 Pembahasan

Hasil penelitian membuktikan bahwa perancangan arsitektur *Semantic Search* dan *Retrieval-Augmented Generation* (RAG) berhasil menghasilkan ekosistem pencarian cerdas yang mengintegrasikan pemahaman bahasa sehari-hari dengan tata kelola dokumen arsip digital di Universitas Darussalam Gontor. Sistem ini dikembangkan dengan berfokus pada adaptasi domain dari model *Sentence Transformer* paraphrase-multilingual-MiniLM-L12-v2 pre-trained, yang dioptimalkan menggunakan metode fine-tuning augmentasi data sintetik (tiga lipatan) serta optimalisasi fungsi *Multiple Negatives Ranking Loss* (MNRL). Implementasi rancang bangun ini melalui integrasi ChromaDB berbasis *cosine similarity* dan pengurutan ulang hibrida dengan bi-encode dan cross-encode (*multilingual Cross-Encoder*) secara jelas dan sukses menciptakan mekanisme pencarian dokumen yang jauh lebih relevan, responsif, dan mampu menutupi celah pada sistem konvensional berbasis kata kunci.

Dari aspek fungsionalitas pencarian informasi (*Information Retrieval*), pengujian kuantitatif terhadap 784 korpus dokumen arsip menunjukkan bahwa ekstraksi semantik yang dilakukan sangat baik. Model MiniLM yang telah melalui fine-tuning berhasil mencapai skor tinggi pada metrik Recall@5 sebesar 0,9936, NDCG@10 sebesar 0,9632, dan MRR@10 sebesar 0,9511. Pencapaian ini secara jelas membuktikan bahwa fitur pencarian berbasis semantik yang dikembangkan mampu berfungsi dengan kualitas pemeringkatan yang melampaui model dasar dan arsitektur besar seperti MPNet. Hasil tersebut menjadi bukti bahwa subsistem pemetaan ruang vektor efektif dalam memprioritaskan dokumen target agar muncul di posisi teratas

secara konsisten.

Selanjutnya, pada aspek kualitas generatif teks, hasil validasi menggunakan arsitektur sistem RAGAS menempatkan arsitektur LLM lokal Gemma 2 (2B) sebagai model LLM penyusun informasi dengan kualifikasi paling layak. Evaluasi model ini mencatatkan perolehan skor *Faithfulness* sebesar 0,97, *Answer Relevancy* sebesar 0,89, dan *Context Precision* sebesar 0,91. Angka-angka tersebut merepresentasikan bahwa susunan narasi jawaban yang disajikan kepada pengguna sangat selaras dengan konteks kueri dan sepenuhnya merujuk pada data yang tercatat dalam arsip kampus. Tingginya skor kesesuaian fakta dari data dokumen ini sekaligus membuktikan bahwa sistem ini sukses mengurangi halusinasi informasi (*AI hallucination*) yang sering menjadi titik lemah model generatif berskala besar.

Sementara itu, analisis kelayakan operasional dari aspek efisiensi komputasi menunjukkan latensi (waktu tunda) yang sangat ideal. Pengujian eksekusi *pipeline* secara terpusat (*end-to-end latency*) menunjukkan bahwa Gemma 2 (2B) mampu menyempurnakan siklus pemrosesan pencarian hingga sintesis akhir dalam waktu rata-rata 6,07 detik. Durasi yang sangat ringkas ini membuktikan bahwa penggunaan model parameter ringan memberikan jaminan responsivitas operasional yang tinggi tanpa memicu penumpukan beban komputasi. Hasil ini mengindikasikan bahwa arsitektur yang dikembangkan memiliki kesesuaian infrastruktur yang baik untuk sistem pencarian informasi semantik pada perguruan tinggi.

Secara keseluruhan, kesimpulan penelitian ini menjelaskan bahwa sistem *Sentence-Transformer* MiniLM-RAG memiliki tingkat akurasi pemeringkatan dan reliabilitas kualitas teks. Penerapan hibridisasi antara model *embedding* berparameter ringan dan kemampuan penalaran LLM dapat memberikan struktur pencarian informasi arsip yang lebih solutif. Secara praktis, arsitektur ini direkomendasikan untuk digunakan sebagai fondasi utama tata kelola layanan arsip digital di perguruan tinggi. Arsitektur sistem ini terbukti tidak sekadar menampilkan dokumen secara statis, melainkan menyajikan interaksi bahasa sehari-hari yang interaktif dan faktual.

BAB V

KESIMPULAN

5.1 Kesimpulan

Merujuk pada rangkaian eksperimen serta evaluasi empiris terhadap perancangan sistem penelusuran arsip digital di Universitas Darussalam Gontor, dapat dirumuskan sejumlah konklusi utama sebagai berikut:

1. Sistem pencarian informasi yang cerdas berhasil dibangun melalui pendekatan *Semantic Search* yang mengintegrasikan model dasar paraphrase-multilingual-MiniLM-L12-v2. Arsitektur ini telah disesuaikan dengan domain arsip akademik melalui augmentasi data sintetik tiga lipatan (*threefold*) serta pengoptimalan ruang vektor menggunakan fungsi *Multiple Negatives Ranking Loss* (MNRL). Pendekatan ini dengan baik mampu menutupi kelemahan fundamental sistem pencarian konvensional yang kerap gagal merelasikan kueri pengguna dengan dokumen secara harfiah.
2. Analisis fungsionalitas pencarian informasi (*Information Retrieval*) membuktikan bahwa model MiniLM yang teraugmentasi menunjukkan keandalan pemeringkatan yang lebih unggul. Pengujian terhadap 784 sampel arsip menunjukkan raihan skor Recall@5 sebesar 0,9936, metrik NDCG@10 sebesar 0,9632, serta perolehan konsistensi posisi puncak melalui MRR@10 sebesar 0,9511. Hasil ini mengonfirmasi bahwa varian model berparameter ringan tersebut mampu menghasilkan akurasi pencarian yang lebih baik dibandingkan dengan arsitektur model dasar miniLM maupun model raksasa MPNet multibahasa.
3. Evaluasi ketat terhadap kualitas teks generatif menggunakan arsitektur *Retrieval-Augmented Generation Assessment* (RAGAS) dengan pengujian 20 kueri pertanyaan menyimpulkan bahwa Gemma 2 (2B) merupakan arsitektur *Large Language Model* (LLM) yang paling sesuai untuk sistem ini. Dari hasil pengujian komparatif, model tersebut mencatatkan performa agregat terbaik dengan skor *Faithfulness* 0,97, *Answer Relevancy* 0,89, dan *Context Precision* 0,91. Stabilitas metrik ini menjamin bahwa setiap narasi jawaban yang dihasilkan bersifat mutlak merujuk pada konteks arsip yang valid, sehingga sistem mengurangi halusinasi pada respons jawaban (*AI hallucination*).
4. Analisis terhadap latensi pemrosesan pada arsitektur sistem menjelaskan

bahwa integrasi antara model *sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 fine-tuned* dengan augmentasi data sintetis, *hybrid reranking* (*Cross-Encoder* dan *Bi-Encoder*), serta RAG berbasis Gemma 2 (2B) menciptakan keseimbangan komputasi yang efisien. Perancangan ini berhasil mencatatkan rata-rata waktu proses menyeluruh (*end-to-end latency*) tercepat, yakni hanya 6,07 detik per kueri. Kinerja ini terbukti lebih unggul dan responsif dibandingkan dengan arsitektur pembandingnya, yaitu Llama 3.2 (3B) yang membutuhkan waktu 6,95 detik, serta Qwen 2.5 (7B) yang memakan waktu terlama hingga 17,22 detik per kueri.

5.2 Saran

Berdasarkan keterbatasan penelitian dan temuan selama proses pengembangan arsitektur AI ini, disarankan beberapa rekomendasi strategis untuk penyempurnaan riset di masa depan:

1. Bagi Perguruan Tinggi (Universitas Darussalam Gontor)

Pengelola pusat data perguruan tinggi direkomendasikan untuk mulai menginisiasi implementasi model awal sistem pencarian semantik ini ke dalam arsitektur arsip administrasi kampus yang sudah ada. Integrasi ini diharapkan dapat mempercepat proses temu kembali dokumen legal, Surat Keputusan (SK), maupun pedoman akademik secara *real-time* guna mendukung efisiensi birokrasi universitas.

2. Bagi Peneliti Selanjutnya

Riset turunan yang ingin mengekspansi skala arsitektur RAG ini disarankan untuk mempertimbangkan beberapa aspek teknis berikut:

- a. Mengadopsi prinsip *Machine Learning Operations* (MLOps) yang tersentralisasi dengan menggunakan ekosistem pustaka seperti MLflow. Pemeliharaan siklus hidup (*lifecycle management*) ini sangat penting untuk melacak penurunan performa model (*model drift*) secara berkala, serta memastikan arsitektur vektor senantiasa adaptif terhadap penambahan variasi struktur dokumen arsip institusi di masa depan.
- b. Menyelenggarakan proses adaptasi domain lanjutan (*fine-tuning*) secara eksplisit pada lapisan parameter utama LLM. Pelatihan ini sebaiknya menggunakan set data instruksional

spesifik (*instruction dataset*) yang memuat ragam kata lokal, terminologi hierarki jabatan kampus, hingga singkatan-singkatan struktural yang eksklusif dan hanya dipahami dalam lingkup internal universitas.

- c. Menelusuri peluang implementasi metode prapemrosesan korpus yang lebih optimal, seperti menggunakan *Vision-Language Model* (VLM), guna mengekstraksi metadata semantik secara langsung dari pindaian arsip fisik berformat citra tanpa harus melewati tahap konversi *Optical Character Recognition* (OCR) tradisional.

3. Bagi Pengembang Sistem Kearsipan dan Arsitek Kecerdasan Buatan

Para pengembang infrastruktur teknologi informasi perguruan tinggi yang berfokus pada implementasi kecerdasan buatan disarankan untuk mengadopsi pendekatan perancangan yang menyeluruh saat membangun ekosistem *Retrieval-Augmented Generation* (RAG). Pengembangan kerangka kerja operasional ini menuntut sinkronisasi pada tiga lapisan komputasi utama: konsistensi algoritma pemetaan vektor sebagai dasar penelusuran (*Retriever*), dinamika sintesis logika dan bahasa oleh agen pemroses teks (*Generator*), serta optimalisasi pengalaman pengguna akhir terkait kecepatan respons dan interaktivitas sistem (*User Experience*). Melalui optimalisasi yang presisi pada ketiga elemen tersebut, kapabilitas teknologi *Natural Language Processing* (NLP) dapat diintegrasikan secara sempurna ke dalam tata kelola administratif. Arsitektur perancangan ini akan memastikan bahwa sistem yang dihasilkan tidak hanya optimal pada tahap pemrosesan data di belakang layar (*backend*), tetapi juga secara nyata mampu menyediakan akses informasi arsip yang akurat, bebas halusinasi, dan sangat relevan dengan kebutuhan penelusuran dokumen seluruh sivitas akademika.

DAFTAR PUSTAKA

- [1] International Organization for Standardization [ISO], “Information and documentation — Records management. En I. O. Standardization, Part 1: Concepts and principles (2nd ed.),” 2016. Accessed: Dec. 24, 2025. [Online]. Available: <https://www.iso.org/standard/62542.html>
- [2] T. Formal, C. Lassance, B. Piwowarski, and S. Clinchant, “Towards Effective and Efficient Sparse Neural Information Retrieval,” *ACM Trans. Inf. Syst.*, vol. 42, no. 5, Apr. 2024, doi: 10.1145/3634912.
- [3] S. Safar, B. R. Jose, J. Mathew, and T. Santhanakrishnan, “Recommendation systems with LLM-based semantic embeddings and FAISS similarity search,” *Neurocomputing*, vol. 649, p. 130753, Oct. 2025, doi: 10.1016/j.neucom.2025.130753.
- [4] V. Karpukhin *et al.*, “Dense passage retrieval for open-domain question answering,” in *EMNLP 2020 - 2020 Conference on Empirical Methods in Natural Language Processing, Proceedings of the Conference*, 2020, pp. 6769–6781. doi: 10.18653/v1/2020.emnlp-main.550.
- [5] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using siamese BERT-networks,” in *EMNLP-IJCNLP 2019 - 2019 Conference on Empirical Methods in Natural Language Processing and 9th International Joint Conference on Natural Language Processing, Proceedings of the Conference*, 2019, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- [6] A. P. Bhopale and A. Tiwari, “Transformer based contextual text representation framework for intelligent information retrieval,” *Expert Syst. Appl.*, vol. 238, p. 121629, Mar. 2024, doi: 10.1016/j.eswa.2023.121629.
- [7] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, “MINILM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers,” in *Advances in Neural Information Processing Systems*, Neural information processing systems foundation, Feb. 2020. Accessed: Dec. 24, 2025. [Online]. Available: <https://arxiv.org/pdf/2002.10957>
- [8] A. P. Putra, D. P. S. Putri, and A. K. A. C. Wiranatha, “Scientific Paper Recommendation System: Application of Sentence Transformers and Cosine Similarity Using arXiv Data,” *J. Appl. Informatics Comput.*, vol. 9, no. 4, pp. 1374–1382, Aug. 2025, doi: 10.30871/JAIC.V9I4.9766.
- [9] T. Afzal, S. Abdul Rauf, M. G. A. Malik, and M. Imran, “Fine-Tuning QurSim on Monolingual and Multilingual Models for Semantic Search,” *Inf. 2025, Vol. 16, Page 84*, vol. 16, no. 2, p. 84, Jan. 2025, doi: 10.3390/INFO16020084.
- [10] H. Steck, C. Ekanadham, and N. Kallus, “Is Cosine-Similarity of Embeddings Really About Similarity?,” *WWW 2024 Companion - Companion Proc. ACM Web Conf.*, pp. 887–890, Mar. 2024, doi: 10.1145/3589335.3651526.
- [11] L. Ma *et al.*, “A Comprehensive Survey on Vector Database: Storage and Retrieval Technique, Challenge,” Mar. 2026, [Online]. Available: <http://arxiv.org/abs/2310.11703>
- [12] A. Z. Abidin and M. M. Engel, “Comparative Analysis of Performance Aspects Between Chroma and Pgvector as a Vector Database,” *bit-Tech*, vol. 8, no. 2, pp. 2079–2090, Dec. 2025, doi: 10.32877/BT.V8I2.3198.
- [13] S. Ghosh *et al.*, “ABEX: Data Augmentation for Low-Resource NLU via Expanding Abstract Descriptions,” *Proc. Annu. Meet. Assoc. Comput. Linguist.*, vol. 1, pp. 726–748, 2024, doi: 10.18653/V1/2024.ACL-LONG.43.
- [14] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, “RAGAs: Automated Evaluation of Retrieval Augmented Generation,” *EACL 2024 - 18th Conf. Eur. Chapter Assoc. Comput. Linguist. Proc. Syst. Demonstr.*, pp. 150–158, 2024, doi:

- 10.18653/V1/2024.EACL-DEMO.16.
- [15] Y. Chen, B. Hu, and Y. Liu, “Optimizing document management and retrieval with multimodal transformers and knowledge graphs,” *PLoS One*, vol. 20, no. 6, p. e0323966, Jun. 2025, doi: 10.1371/JOURNAL.PONE.0323966.
 - [16] P. Posokhov, S. Skrylnikov, S. Masliukhin, A. Zavgorodniaia, O. Koroteeva, and Y. Matveev, “Query-Adaptive Hybrid Search,” *Mach. Learn. Knowl. Extr. 2026, Vol. 8, Page 91*, vol. 8, no. 4, p. 91, Apr. 2026, doi: 10.3390/MAKE8040091.
 - [17] J. Guo, Y. Cai, Y. Fan, F. Sun, R. Zhang, and X. Cheng, “Semantic Models for the First-Stage Retrieval: A Comprehensive Review,” *ACM Trans. Inf. Syst.*, vol. 40, no. 4, Oct. 2022, doi: 10.1145/3486250;WGROU:STRING:ACM.
 - [18] D. Zhou, F. Shao, J. Zhang, Y. Zhang, and S. Feng, “Multi-scale orthogonal Gabor filters based ConvNets for illumination robust single sample face recognition,” *Eng. Appl. Artif. Intell.*, vol. 163, p. 113143, Jan. 2026, doi: 10.1016/J.ENGAPPAL.2025.113143.
 - [19] A. K. Uysal and S. Gunal, “The impact of preprocessing on text classification,” *Inf. Process. Manag.*, vol. 50, no. 1, pp. 104–112, Jan. 2014, doi: 10.1016/j.ipm.2013.08.006.
 - [20] L. D. Krisnawati, A. W. Mahastama, S.-C. Haw, K.-W. Ng, and P. Naveen, “Indonesian-English Textual Similarity Detection Using Universal Sentence Encoder (USE) and Facebook AI Similarity Search (FAISS),” *CommIT (Communication Inf. Technol. J.)*, vol. 18, no. 2, pp. 183–195, Sep. 2024, doi: 10.21512/commit.v18i2.11274.
 - [21] Y. Tay, M. Dehghani, D. Bahri, and D. Metzler, “Efficient Transformers: A Survey,” *ACM Comput. Surv.*, vol. 55, no. 6, Jun. 2023, doi: 10.1145/3530811;JOURNAL:JOURNAL:CSUR;WGROU:STRING:ACM.
 - [22] Y. A. Malkov and D. A. Yashunin, “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 42, no. 4, pp. 824–836, Apr. 2020, doi: 10.1109/TPAMI.2018.2889473.
 - [23] Y. Gao *et al.*, “Retrieval-Augmented Generation for Large Language Models: A Survey,” *Proc. - 2024 Conf. AI, Sci. Eng. Technol. AIXSET 2024*, pp. 166–169, Dec. 2023, doi: 10.1109/AIXSET62544.2024.00030.
 - [24] M. T. Colangelo, M. Meleti, S. Guizzardi, E. Calciolari, and C. Galli, “A Comparative Analysis of Sentence Transformer Models for Automated Journal Recommendation Using PubMed Metadata,” *Big Data Cogn. Comput.*, vol. 9, no. 3, p. 67, Mar. 2025, doi: 10.3390/BDCC9030067/S1.
 - [25] S. Roychowdhury *et al.*, “Investigating Distributions of Telecom Adapted Sentence Embeddings for Document Retrieval,” Jun. 2024, Accessed: Apr. 13, 2026. [Online]. Available: <https://arxiv.org/pdf/2406.12336>
 - [26] K. Wang, N. Thakur, N. Reimers, and I. Gurevych, “GPL: Generative Pseudo Labeling for Unsupervised Domain Adaptation of Dense Retrieval,” *NAACL 2022 - 2022 Conf. North Am. Chapter Assoc. Comput. Linguist. Hum. Lang. Technol. Proc. Conf.*, pp. 2345–2350, Dec. 2021, doi: 10.18653/v1/2022.naacl-main.168.
 - [27] N. F. Liu *et al.*, “Lost in the Middle: How Language Models Use Long Contexts,” *Trans. Assoc. Comput. Linguist.*, vol. 12, pp. 157–173, Dec. 2024, doi: 10.1162/TACL_A_00638/119630.
 - [28] G. Team *et al.*, “Gemma 2: Improving Open Language Models at a Practical Size,” Jul. 2024, Accessed: Jul. 24, 2026. [Online]. Available: <https://arxiv.org/pdf/2408.00118>
 - [29] A. Yang *et al.*, “Qwen2 Technical Report,” Jul. 2024, Accessed: Jul. 24, 2026.

- [Online]. Available: <https://arxiv.org/pdf/2407.10671>
- [30] N. Muennighoff, N. Tazi, L. Magne, and N. Reimers, “MTEB: Massive Text Embedding Benchmark,” *EACL 2023 - 17th Conf. Eur. Chapter Assoc. Comput. Linguist. Proc. Conf.*, pp. 2014–2037, 2023, doi: 10.18653/V1/2023.EACL-MAIN.148.
 - [31] A. W. Anggoro, P. Corcoran, D. De Widt, and Y. Li, “Harmonized system code classification using supervised contrastive learning with sentence BERT and multiple negative ranking loss,” *Data Technol. Appl.*, vol. 59, no. 2, pp. 276–301, Apr. 2025, doi: 10.1108/DTA-01-2024-0052.
 - [32] L. Wang *et al.*, “Text Embeddings by Weakly-Supervised Contrastive Pre-training,” Dec. 2022, Accessed: Jul. 24, 2026. [Online]. Available: <https://arxiv.org/pdf/2212.03533>
 - [33] Z. Ji *et al.*, “Survey of Hallucination in Natural Language Generation,” Dec. 31, 2023, *Association for Computing Machinery*. doi: 10.1145/3571730.
 - [34] W. Kwon *et al.*, “Efficient Memory Management for Large Language Model Serving with PagedAttention,” *SOSP 2023 - Proc. 29th ACM Symp. Oper. Syst. Princ.*, pp. 611–626, Oct. 2023, doi: 10.1145/3600006.3613165;CSUBTYPE:STRING:CONFERENCE.
 - [35] M. Treviso *et al.*, “Efficient Methods for Natural Language Processing: A Survey,” *Trans. Assoc. Comput. Linguist.*, vol. 11, pp. 826–860, Dec. 2023, doi: 10.1162/TACL_A_00577/116725.

LAMPIRAN

Lampiran 1. Evaluasi RAGAS 20 kueri

isi_inout	interviewed_contacts	response	reference	faithful	answer_relev	content_prec
1. Untuk apa tim penumus visi dan misi UNDA Gontor dibuat?	[pengangkatan tim penumus visi dan misi universitas daussalam gontor. dokumen ini b	Tim penumus visi dan misi UNDA Gontor dibuat untuk menyusun visi dan misi univ	Tim tersebut dibuat berdasarkan amanat rektor untuk merumuskan visi dan misi Unive	10	8.55532E+5	999999999
2. Siapa yang mengesahkan visi dan misi UNDA Gontor?	[visi dan misi universitas daussalam gontor. dokumen ini berisi tentang visi dan misi univ	Rektor Universitas Daussalam Gontor	Pengesahan visi dan misi oleh Rektor Universitas Daussalam Gontor	10	8.36859E+5	999999999
3. Siapa yang menetapkan struktur fungsional CIES?	[penetapan struktur fungsional centre for islamic economic studies cie	Struktur fungsional CIES ditetapkan oleh Rektor Universitas Daussalam Gontor	Struktur fungsional Centre for Islamic Economic Studies (CIES) ditetapkan oleh Rektor	10	8.05864E+5	999999999
4. Buku pedoman penelitian dan plm unda. buku pedoman ini telah disediakan dengan	[buku pedoman penelitian dan plm unda. buku pedoman ini telah disediakan dengan	Buku pedoman penelitian dan PKM UNDA berfungsi sebagai pedoman pelaksanaan p	Buku ini menjadi pedoman pelaksanaan program hibah internal penelitian dan pengabd	10	8.34798E+5	9.42057E+5
5. Program ujian bahasa tiap semester di UNDA bertujuan untuk apa?	[penyediaan program ujian bahasa mahasiswa pada setiap semester. dokumen ini ber	Program ujian bahasa tiap semester di UNDA bertujuan untuk meningkatkan dan menge	Program ini disediakan untuk menunjang peningkatan kemampuan bahasa Arab dan	3.3333E+5	9.53146E+5	999999999
6. Panitia apa yang diangkat untuk badan qudr di kampus A?	[pengangkatan panitia badan qudr. dokumen ini berisi tentang pengangkatan pan	Berdasarkan visi misi, panitia yang diangkat untuk badan qudr di kampus A adal	Rektor mengangkat panitia badan qudr guna kelancaran pelaksanaan badan qudr	10	8.70239E+5	8E+5
7. Berapa rentang waktu rencana induk pengembangan UNDA Gontor?	[penetapan rencana induk pengembangan 2018-2040. dokumen ini berisi tentang pen	Rencana induk pengembangan UNDA Gontor berlaku dari tahun 2018 hingga tahun 20	Rencana induk pengembangan atau disebut REMP tahun 2018 sampai dengan tahun	10	8.23102E+4	8.8E+3
8. Apa tujuan kebijakan SPMI di UNDA Gontor?	[tujuan kebijakan spmi. tereslegannya pendidikan, penelitian, dan pengabdian kepa	Tujuan kebijakan SPMI di UNDA Gontor adalah untuk memberikan setiap legasan se	Kebijakan SPMI bertujuan meningkatkan relevansi amfotir akademik serta daya saing	10	8.71011E+5	333333333
9. Siapa yang mengeluarkan SK pengangkatan Rektor UNDA Gontor?	[pengangkatan rektor. dokumen ini berisi tentang keputusan ketua yayasan perguruan	Keputusan pengangkatan Rektor UNDA Gontor dikeluarkan oleh Ketua Yayasan Perg	SK pengangkatan Rektor dikeluarkan oleh Ketua Yayasan Perguruan Tinggi Daussa	10	8.30877E+5	999999999
10. Apa tugas utama Pusat Bahasa yang didirikan di UNDA?	[pendirian pusat bahasa. dokumen ini berisi tentang pendirian pusat bahasa selajuga	Pusat Bahasa yang didirikan di UNDA berfungsi sebagai lembaga standar isi, proses, dan evaluasi bahasa	Pusat bahasa sebagai biro yang menangani standar isi, proses, dan evaluasi bahasa d	10	7.28503E+4	999999999
11. Bagaimana status alihrekat Prodi Ilmu Gizi UNDA saat ini?	[status universitas daussalam gontor. status adalah pedoman dasar penyelenggaraan	Status adalah pedoman dasar penyelenggaraan kegiatan yang berlaku dari 24	Status berfungsi sebagai pedoman dasar penyelenggaraan kegiatan, mulai dari pene	10	8.36308E+5	999999999
12. Bagaimana cara jika ingin mengajukan Sendor?	[pengajuan sendor. dokumen ini berisi tentang pengajuan rektor perhalatentuhan	Hasil seleksi penerimaan mahasiswa baru gelombang pertama Universitas Dauss	Hasil seleksi penerimaan mahasiswa baru gelombang pertama Universitas Dauss	10	7.41233E+4	499999995
13. Apa tujuan pendirian US di UNDA Gontor?	[pendirian unit usaha unda gontor. dokumen ini berisi tentang pengesahan pendiri	Tujuan pendirian US di UNDA Gontor adalah untuk menyediakan layanan pemenuhan ke	Pendirian unit usaha UNDA Gontor atau US guna menyediakan layanan pemenuhan ke	10	8.65744E+5	999999999

Gambar 7. Evaluasi RAGAS 20 kueri pada model Gemma

isi_inout	interviewed_contacts	response	reference	faithful	answer_relev	content_prec
1. Untuk apa tim penumus visi dan misi UNDA Gontor dibuat?	[pengangkatan tim penumus visi dan misi universitas daussalam gontor. dokumen ini b	Tim penumus visi dan misi Universitas Daussalam Gontor dibuat untuk menyusun visi	Tim tersebut dibuat berdasarkan amanat rektor untuk merumuskan visi dan misi Unive	10	7.52978E+5	999999999
2. Siapa yang mengesahkan visi dan misi UNDA Gontor?	[visi dan misi universitas daussalam gontor. dokumen ini berisi tentang visi dan misi univ	Rektor Universitas Daussalam Gontor mengesahkan visi dan misi universitas terseb	Pengesahan visi dan misi oleh Rektor Universitas Daussalam Gontor	10	8.28518E+5	999999999
3. Siapa yang menetapkan struktur fungsional CIES?	[penetapan struktur fungsional centre for islamic economic studies cie	Struktur fungsional CIES ditetapkan oleh Rektor Universitas Daussalam Gontor	Struktur fungsional Centre for Islamic Economic Studies (CIES) ditetapkan oleh Rektor	5	8.45238E+5	999999999
4. Buku pedoman penelitian dan plm unda. buku pedoman ini telah disediakan dengan	[buku pedoman penelitian dan plm unda. buku pedoman ini telah disediakan dengan	Buku pedoman penelitian dan PKM UNDA berfungsi untuk menjamin efisiensi, transpar	Buku ini menjadi pedoman pelaksanaan program hibah internal penelitian dan pengabd	6	8.52074E+5	9.42057E+5
5. Program ujian bahasa tiap semester di UNDA bertujuan untuk apa?	[penyediaan program ujian bahasa mahasiswa pada setiap semester. dokumen ini ber	Program ujian bahasa tiap semester di UNDA bertujuan untuk meningkatkan dan menge	Program ini disediakan untuk menunjang peningkatan kemampuan bahasa Arab dan	10	8.53261E+5	999999999
6. Panitia apa yang diangkat untuk badan qudr di kampus A?	[pengangkatan panitia badan qudr. dokumen ini berisi tentang pengangkatan pan	Berdasarkan visi misi, panitia yang diangkat untuk badan qudr di kampus A adal	Rektor mengangkat panitia badan qudr guna kelancaran pelaksanaan badan qudr	10	8.13753E+5	8E+5
7. Berapa rentang waktu rencana induk pengembangan UNDA Gontor?	[penetapan rencana induk pengembangan 2018-2040. dokumen ini berisi tentang pen	Rencana induk pengembangan UNDA Gontor memiliki rentang waktu dari tahun 2018 s	Rencana induk pengembangan atau disebut REMP tahun 2018 sampai dengan tahun	10	8.55866E+5	8.8E+3
8. Apa tujuan kebijakan SPMI di UNDA Gontor?	[tujuan kebijakan spmi. tereslegannya pendidikan, penelitian, dan pengabdian kepa	Tujuan kebijakan SPMI di UNDA Gontor adalah untuk memberikan setiap legasan se	Kebijakan SPMI bertujuan meningkatkan relevansi amfotir akademik serta daya saing	10	8.72091E+5	333333333
9. Siapa yang mengeluarkan SK pengangkatan Rektor UNDA Gontor?	[pengangkatan rektor. dokumen ini berisi tentang keputusan ketua yayasan perguruan	Keputusan pengangkatan Rektor Universitas Daussalam Gontor bertanggung jawab un	SK pengangkatan Rektor dikeluarkan oleh Ketua Yayasan Perguruan Tinggi Daussa	0	0	999999999
10. Apa tugas utama Pusat Bahasa yang didirikan di UNDA?	[pendirian pusat bahasa. dokumen ini berisi tentang pendirian pusat bahasa selajuga	Pusat Bahasa yang didirikan di Universitas Daussalam Gontor berfungsi sebagi un	Pusat bahasa sebagai biro yang menangani standar isi, proses, dan evaluasi bahasa d	10	6.71267E+5	999999999
11. Bagaimana status alihrekat Prodi Ilmu Gizi UNDA saat ini?	[status universitas daussalam gontor. status adalah pedoman dasar penyelenggaraan	Status adalah pedoman dasar penyelenggaraan kegiatan yang berlaku dari 24	Status berfungsi sebagai pedoman dasar penyelenggaraan kegiatan, mulai dari pene	0	0	999999999
12. Bagaimana cara jika ingin mengajukan Sendor di unda?	[pengajuan sendor. dokumen ini berisi tentang pengajuan rektor perhalatentuhan	Hasil seleksi penerimaan mahasiswa baru gelombang pertama tercatat untuk tahun a	Hasil seleksi penerimaan mahasiswa baru gelombang pertama Universitas Daussalam C	5	6.76806E+4	499999995
13. Apa tujuan pendirian US di UNDA Gontor?	[pendirian unit usaha unda gontor. dokumen ini berisi tentang pengesahan pendiri	Tujuan pendirian US di UNDA Gontor adalah untuk menyediakan layanan pemenuhan ke	Pendirian unit usaha UNDA Gontor atau US guna menyediakan layanan pemenuhan ke	10	8.65622E+5	999999999

Gambar 6. Evaluasi RAGAS 20 kueri pada model Qwen

isi_inout	interviewed_contacts	response	reference	faithful	answer_relev	content_prec
1. Untuk apa tim penumus visi dan misi UNDA Gontor dibuat?	[pengangkatan tim penumus visi dan misi universitas daussalam gontor. dokumen ini b	Tim tersebut dibuat berdasarkan amanat rektor untuk merumuskan visi dan misi univ	Tim tersebut dibuat berdasarkan amanat rektor untuk merumuskan visi dan misi Unive	10	7.65596E+5	999999999
2. Siapa yang mengesahkan visi dan misi UNDA Gontor?	[visi dan misi universitas daussalam gontor. dokumen ini berisi tentang visi dan misi univ	Rektor Universitas Daussalam Gontor mengesahkan visi dan misi universitas terseb	Pengesahan visi dan misi oleh Rektor Universitas Daussalam Gontor	10	8.16757E+5	999999999
3. Siapa yang menetapkan struktur fungsional CIES?	[penetapan struktur fungsional centre for islamic economic studies cie	Struktur fungsional CIES ditetapkan oleh Rektor Universitas Daussalam Gontor	Struktur fungsional Centre for Islamic Economic Studies (CIES) ditetapkan oleh Rektor	3	8.88569E+5	999999999
4. Buku pedoman penelitian dan plm unda. buku pedoman ini telah disediakan dengan	[buku pedoman penelitian dan plm unda. buku pedoman ini telah disediakan dengan	Buku pedoman penelitian dan PKM UNDA berfungsi untuk menjamin efisiensi, transpar	Buku ini menjadi pedoman pelaksanaan program hibah internal penelitian dan pengabd	5	8.86176E+5	9.42057E+5
5. Program ujian bahasa tiap semester di UNDA bertujuan untuk apa?	[penyediaan program ujian bahasa mahasiswa pada setiap semester. dokumen ini ber	Program ujian bahasa tiap semester di UNDA bertujuan untuk meningkatkan dan menge	Program ini disediakan untuk menunjang peningkatan kemampuan bahasa Arab dan	10	8.06149E+5	999999999
6. Panitia apa yang diangkat untuk badan qudr di kampus A?	[pengangkatan panitia badan qudr. dokumen ini berisi tentang pengangkatan pan	Berdasarkan dokumen yang tersedia, panitia badan qudr yang diangkat adalah Pan	Rektor mengpu panitia badan qudr guna kelancaran pelaksanaan badan qudr	10	7.60526E+5	8E+5
7. Berapa rentang waktu rencana induk pengembangan UNDA Gontor?	[penetapan rencana induk pengembangan 2018-2040. dokumen ini berisi tentang pen	Rencana induk rencana induk Berentang waktu rencana induk pengembangan UNDA G	Rencana induk pengembangan atau disebut REMP tahun 2018 sampai dengan tahun	10	8.20303E+4	8.8E+3
8. Apa tujuan kebijakan SPMI di UNDA Gontor?	[tujuan kebijakan spmi. tereslegannya pendidikan, penelitian, dan pengabdian kepa	Tujuan kebijakan SPMI (Sistem Penjaminan Mutu Internal) di UNDA Gontor adalah un	Kebijakan SPMI bertujuan meningkatkan relevansi amfotir akademik serta daya saing	10	8.71747E+5	333333333
9. Siapa yang mengeluarkan SK pengangkatan Rektor UNDA Gontor?	[pengangkatan rektor. dokumen ini berisi tentang keputusan ketua yayasan perguruan	Keputusan pengangkatan Rektor Universitas Daussalam Gontor dikeluarkan oleh Re	SK pengangkatan Rektor dikeluarkan oleh Ketua Yayasan Perguruan Tinggi Daussa	10	8.95502E+5	999999999
10. Apa tugas utama Pusat Bahasa yang didirikan di UNDA?	[pendirian pusat bahasa. dokumen ini berisi tentang pendirian pusat bahasa selajuga	Pusat Bahasa yang didirikan di UNDA berfungsi sebagai lembaga yang menangani stan	Pusat bahasa sebagai biro yang menangani standar isi, proses, dan evaluasi bahasa d	10	8.03261E+5	999999999
11. Bagaimana status alihrekat Prodi Ilmu Gizi UNDA saat ini?	[status universitas daussalam gontor. status adalah pedoman dasar penyelenggaraan	Status adalah pedoman dasar penyelenggaraan kegiatan yang berlaku dari 24	Status berfungsi sebagai pedoman dasar penyelenggaraan kegiatan, mulai dari pene	10	7.17255E+5	999999999
12. Bagaimana cara jika ingin mengajukan Sendor di unda?	[pengajuan sendor. dokumen ini berisi tentang pengajuan rektor perhalatentuhan	Hasil seleksi penerimaan mahasiswa baru gelombang pertama tercatat untuk tahun a	Hasil seleksi penerimaan mahasiswa baru gelombang pertama Universitas Daussalam C	5	6.76875E+4	499999995
13. Apa tujuan pendirian US di UNDA Gontor?	[pendirian unit usaha unda gontor. dokumen ini berisi tentang pengesahan pendiri	Tujuan pendirian US di UNDA Gontor adalah untuk menyediakan layanan pemenuhan ke	Pendirian unit usaha UNDA Gontor atau US guna menyediakan layanan pemenuhan ke	10	8.71243E+5	999999999

Gambar 5. Evaluasi RAGAS 20 kueri pada model Llama

Lampiran 2. Inference Semantic Search

The screenshot displays a user interface for semantic search inference. At the top, a text input field contains the query: "saya sedang mengerjakan skripsi, jadi jelaskan bagaimana aturan ujian skripsi !". Below the input is a red button labeled "Cari Jawaban ✨".

The "Jawaban Sistem" (System Answer) section features a light blue box with a lightbulb icon and the text: "Berikut adalah langkah-langkah pelaksanaan ujian skripsi berdasarkan SOP ujian skripsi:". This is followed by a numbered list of six steps: 1. Pengajuan persyaratan, 2. Penjadwalan ujian, 3. Pembentukan tim penguji, 4. Pelaksanaan presentasi dan tanya jawab, 5. Proses penilaian, and 6. Penetapan kelulusan.

The "Metrik Inferensi" (Inference Metrics) section is a dark blue box containing a table of performance metrics:

Metrik Inferensi	Total Waktu	Pencarian Vektor	Reranking	Generasi LLM
	2.16 s	0.05 s	0.47 s	1.64 s

The "Referensi Arsip Ditemukan (5 Dokumen)" (Archived References Found (5 Documents)) section is a light blue box with a document icon. It shows a list of references, with the top result being "Top 1 | SOP Ujian Skripsi (Skor Relevansi: 0.612)".

Gambar 8. Inference Semantic Search

Lampiran 3. Hasil Premrosesan Dataset

```

1 {"title": "pengangkatan tim perumus visi dan misi universitas darussalam gontor", "content": "dokumen ini berisi tentang visi dan misi universitas darussalam gontor"}
2 {"title": "visi dan misi universitas darussalam gontor", "content": "dokumen ini berisi tentang visi dan misi universitas darussalam gontor"}
3 {"title": "penetapan struktur fungsionaris centre for islamic economic studies cies", "content": "dokumen ini berisi tentang nama - nama terlampir sebagai"}
4 {"title": "peraturan akademik universitas darussalam gontor", "content": "dokumen ini berisi tentang naskah peraturan akademik universitas darussalam gontor"}
5 {"title": "pemberlakuan buku pedoman penelitian dan pkm", "content": "dokumen ini berisi tentang pengesahan buku pedoman serta pengesahan buku pedoman penelitian dan pkm"}
6 {"title": "pemberlakuan program ujian bahasa mahasiswa pada setiap semester", "content": "dokumen ini berisi tentang pemberlakuan program ujian bahasa mahasiswa pada setiap semester"}
7 {"title": "pengangkatan panitia ujian akhir semester gasal", "content": "dokumen ini berisi tentang pengangkatan panitia ujian akhir semester gasal"}
8 {"title": "penetapan panitia pelaksana rektor cup", "content": "dokumen ini berisi tentang pengangkatan nama - nama terlampir sebagai panitia pelaksana rektor cup"}
9 {"title": "pengangkatan ketua panitia career and entrepreneur fair 2.0", "content": "dokumen ini berisi tentang pengangkatan saudara ketua panitia career and entrepreneur fair 2.0"}
10 {"title": "pengangkatan panitia pembekalan wisudawan wati ke 40", "content": "dokumen ini berisi tentang pengangkatan panitia pembekalan wisudawan wati ke 40"}
11 {"title": "pengangkatan panitia wisuda sarjana dan pascasarjana angkatan ke 40", "content": "dokumen ini berisi tentang pengangkatan panitia wisuda sarjana dan pascasarjana angkatan ke 40"}
12 {"title": "pengangkatan panitia penerimaan mahasiswa baru", "content": "dokumen ini berisi tentang pengangkatan panitia penerimaan mahasiswa baru"}
13 {"title": "pengangkatan panitia ujian tengah semester genap", "content": "dokumen ini berisi tentang pengangkatan panitia ujian tengah semester genap"}
14 {"title": "pengangkatan panitia ibadah qurban", "content": "dokumen ini berisi tentang pengangkatan panitia ibadah qurban di kampus a"}
15 {"title": "pengangkatan panitia wisuda sarjana dan pascasarjana angkatan ke 38", "content": "dokumen ini berisi tentang pengangkatan panitia wisuda sarjana dan pascasarjana angkatan ke 38"}
16 {"title": "rekognisi karya prestasi mahasiswa", "content": "dokumen ini berisi tentang naskah rekognisi karya prestasi mahasiswa"}
17 {"title": "pedoman kurikulum merdeka belajar", "content": "dokumen ini berisi tentang pengesahan pedoman kurikulum merdeka belajar"}
18 {"title": "alokasi penelitian dan pengabdian kepada masyarakat berbasis islamisasi ilmu pengetahuan kontemporer", "content": "dokumen ini berisi tentang alokasi penelitian dan pengabdian kepada masyarakat berbasis islamisasi ilmu pengetahuan kontemporer"}
19 {"title": "penetapan pedoman penugasan dosen", "content": "dokumen ini berisi tentang penetapan naskah pedoman penugasan dosen universitas darussalam gontor"}
20 {"title": "pedoman rancangan dan monitoring kerjasama biro kerjasama, alumni, dan masyarakat", "content": "dokumen ini berisi tentang pedoman rancangan dan monitoring kerjasama biro kerjasama, alumni, dan masyarakat"}
21 {"title": "penetapan pedoman integrasi penelitian dan pengabdian kepada masyarakat dalam pembelajaran", "content": "dokumen ini berisi tentang penetapan pedoman integrasi penelitian dan pengabdian kepada masyarakat dalam pembelajaran"}
22 {"title": "penetapan panitia pekan pengenalan khutbatul arsy", "content": "dokumen ini berisi tentang penetapan panitia pekan pengenalan khutbatul arsy"}
23 {"title": "pengangkatan panitia workshop peningkatan keterampilan dasar teknik intruksional pekerti", "content": "dokumen ini berisi tentang pengangkatan panitia workshop peningkatan keterampilan dasar teknik intruksional pekerti"}
24 {"title": "panitia ibadah kurban", "content": "dokumen ini berisi tentang pengangkatan panitia ibadah hari raya qurban guna kelancaran ibadah kurban"}
25 {"title": "pengangkatan ketua panitia ibadah kurban", "content": "dokumen ini berisi tentang pengangkatan muhammad syifaurosyidin, ketua panitia ibadah kurban"}
26 {"title": "pengangkatan panitia wisuda sarjana dan pascasarjana angkatan 39", "content": "dokumen ini berisi tentang pengangkatan panitia wisuda sarjana dan pascasarjana angkatan 39"}
27 {"title": "pengangkatan panitia ujian tengah semester gasal", "content": "dokumen ini berisi tentang pengangkatan panitia ujian tengah semester gasal"}

```

Gambar 10. Hasil Pemrosesan Dataset

Metrik Inferensi


Total Waktu	Pencarian Vektor	Reranking	Generasi LLM
2.16 s	0.05 s	0.47 s	1.64 s

Referensi Arsip Ditemukan (5 Dokumen)

- Top 1 | SOP Ujian Skripsi (Skor Relevansi: 0.612)
- Top 2 | SOP Ujian Proposal Skripsi (Skor Relevansi: 0.474)
- Top 3 | SOP Ujian Skripsi (Skor Relevansi: 0.375)
- Top 4 | SOP Pengesahan Skripsi Pasca Ujian (Skor Relevansi: 0.321)
- Top 5 | SOP Ujian Komprehensif (Skor Relevansi: 0.242)

Gambar 9. Inference Semantic Search

Lampiran 4. Visualisasi Hasil Kualitas dan Latency pada Model LLM



Gambar 11. Perbandingan Kualitas dan Latency Tiap Model LLM